Stochastik für Informatiker



Dr. rer. nat. Johannes Riesterer

Beispiel Entscheidungsfindung - Problemstellung

Es werden N=10.000 Orangen geliefert. Ist mehr als 5% der Ware verfault, kann der Käufer die Lieferung an den Verkäufer zurückgehen lassen. Alle Orangen anschauen ist wegen der Menge allerdings unmöglich.

Beispiel Entscheidungsfindung - Problemstellung

Der Käufer wählt eine Stichprobenmenge von n=50 Orangen und möchte anhand einer Grenze c an faulen Orangen innerhalb dieser Stichprobe entscheiden, ob er die Lieferung zurückgehen lässt oder nicht. Er wendet also die folgende Entscheidungsregel an:

höchsten c Orangen faul \Rightarrow Lieferung akzeptieren mehr als c Orangen faul \Rightarrow Lieferung zurückgehen lassen.

Beispiel Entscheidungsfindung - Problemstellung

Wie sollte c gewählt werden?

Beispiel Entscheidungsfindung - Modell

Man möchte auf der einen Seite, dass die Wahrscheinlichkeit dafür, dass die Lieferung mehr als 5% faule Orangen enthält nicht erkannt wird, klein ist. Auf der anderen Seite möchte man auch, dass die Wahrscheinlichkeit für einen "peinlichen" Fehler, dass die Lieferung zurück geht, obwohl sie weniger als 5% faule Orangen enthält, ebenfalls klein ist.

Beispiel Entscheidungsfindung - Problemstellung

Wie sollte c gewählt werden?

Beispiel Entscheidungsfindung - Modell

Man möchte auf der einen Seite, dass die Wahrscheinlichkeit dafür, dass die Lieferung mehr als 5% faule Orangen enthält nicht erkannt wird, klein ist. Auf der anderen Seite möchte man auch, dass die Wahrscheinlichkeit für einen "peinlichen" Fehler, dass die Lieferung zurück geht, obwohl sie weniger als 5% faule Orangen enthält, ebenfalls klein ist.

Beispiel Entscheidungsfindung - Modell

Wir modellieren die Anzahl x der faulen Orangen einer Stichprobe n aus der Grundmenge N als "hypergeometrische" Verteilung, wobei die Zahl ω der insgesamt faulen Orangen innerhalb N unbekannt is.

$$P_{\omega}(x=m) = \frac{\binom{\omega}{m} \cdot \binom{N-\omega}{n-m}}{\binom{N}{n}}$$

Beispiel Entscheidungsfindung - Modell

Ist x die Anzahl der faulen Orangen in einer Stichprobe n=50, so lauten unsere vorigen Überlegung mit Hilfe des Modells: Wähle Schranke c für faule Orangen in Stichprobe so, dass für $\alpha=0.025$

$$P_{\omega}(x>c) für $\omega<500(=5\%$ von $N=10.000)$ $P_{\omega}(x>c)$ möglichst groß für $\omega>500$$$

gilt.

Beispiel Entscheidungsfindung - Modell

Die genaue Bestimmung von c ist auf den ersten Blick nicht so einfach. Wir werden das Problem auf eine einfachere Situation, einen sogenannten Neyman-Pearson-Test, zurückführen.



Test

Sei $(\mathcal{X}, \mathcal{F}, P_{\rho}: \rho \in \Theta)$ ein statistisches Modell und $\Theta = \Theta_0 \cup \Theta_1$ eine Zerlegung. Wir nennen $H_0: \rho \in \Theta_0$ die Nullhypothese und $H_1: \rho \in \Theta_1$ die Alternative und eine Statistik $\varphi: \mathcal{X} \to [0,1]$ einen Test von H_0 gegen H_1 . $\{x \in \mathcal{X}: \varphi(x) = 1\}$ heißt Ablehnungsbereich und $\{x \in \mathcal{X}: \varphi(x) = 0\}$ Annahmebereich des Tests φ

Gütefunktion

Die Funktion $G_{\varphi}: \Theta \to [0, \infty), G_{\varphi}(\rho) = \mathbb{E}_{\rho}(\varphi)$ heißt Gütefunktion des Tests.

Beispiel

Im Beispiel der Orangenlieferung ist $\mathcal{X}:=\{0,\cdots,n\}$ und wir wählen $\Theta_0=\{0,\cdots\omega_0\}$ und $\Theta_1=\{\omega_0+1,\cdots N\}$ mit $\omega_0=500$ und betrachten den Test

$$\varphi(x) = \begin{cases} 1 \text{ falls } x > c \\ 0 \text{ falls } x \le c \end{cases}$$

zur Hypothese $H_0: \rho \in \Theta_0$ und der Alternative $H_1: \rho \in \Theta_1$.

Signifikanz-Niveau

Die im ungünstigen Fall vorliegende Wahrscheinlichkeit für einen Fehler erster Art ist $\sup_{\rho\in\Theta_0}\mathbb{E}_{\rho}(\varphi)$. Sie heißt Niveau von φ . Ein Test hat das (Signifikanz-)Niveau α , falls $\sup_{\rho\in\Theta_0}\mathbb{E}(\varphi)\leq\alpha$.

Macht

Für $\rho \in \Theta_1$ heißt $G_{\varphi}(\rho)$ die Macht von φ bei ρ . Sie ist die Wahrscheinlichkeit, mit der die Alternative erkannt wird, wenn sie vorliegt und $\beta_{\varphi}(\rho) = 1 - G_{\varphi}(\rho)$ ist die Wahrscheinlichkeit für einen Fehler zweiter Art, nämlich dass das Vorliegen der Alternative nicht erkannt wird und deshalb die Nullhypothese fälschlich akzeptiert wird.

Gütefunktion eines Binomialtests mit n=30. Für alle Werte von p aus der Nullhypothese $H0: p \leq 0, 2$ liegt G(p) unter dem Signifikanzniveau $\alpha=5\%$.




Figure: Quelle: Wikipedia

Gütefunktion

Ein Test φ von H_0 gegen H_1 heißt bester Test zum Niveau α , falls für jeden anderen Test ψ zum Niveau α gilt:

$$G_{\varphi}(\rho) \geq G_{\psi}(\rho)$$
 für alle $\rho \in \Theta_1$

Er erkennt also von allen Tests am Besten die Alternative unter Einhaltung des Signifikanz-Niveau für den ungünstigen Fehler.

Neyman-Pearson-Test

Sei $(\mathcal{X}, \mathcal{F}, P_0, P_1)$ ein statistisches Modell mit $\Theta = \{0, 1\}$ und Dichten p_0 und p_1 von P_0 und P_1 und dem Likelyhood-Quotienten

$$R(X) = \begin{cases} \frac{p_1(x)}{p_0(x)} & \text{falls } p_0(x) > 0\\ \infty & \text{falls } p_0(x) = 0 \end{cases}$$

. Der Test

$$\varphi(x) = \begin{cases} 1 \text{ falls } R(x) > c \\ 0 \text{ falls } R(x) < c \end{cases}$$

heißt Neyman-Pearson-Test zum Schwellwert c. R(x) = c kann hierbei beliebig gesetzt werden.

Neyman-Pearson Lemma


Sei $(\mathcal{X}, \mathcal{F}, P_0, P_1)$ ein statistisches Modell. Dann gilt:

- **1** Zu gegebenen α gibt es einen Neyman-Pearson-Test φ mit Niveau $\mathbb{E}_0(\varphi) = \alpha$.
- ② Dieser Test ist ein bester Test zum Niveau α . Jeder Beste Test zum Niveau α ist nicht unterscheidbar von diesem.

Quantil und Fraktil

Sei Q ein Wahrscheinlichkeitsmass auf $(\mathbb{R},\mathcal{B}(\mathbb{R}))$ und $0<\alpha<1$. Dann heißt jede Zahl $q\in\mathbb{R}$ mit $Q((-\infty,q])\geq \alpha$ und $Q((q,\infty))\geq 1-\alpha$ ein α -Quantil von Q.

- $\alpha = \frac{1}{2}$ heißt Media.
- $\alpha = \frac{1}{4}$ und $\alpha = \frac{3}{4}$ heißen Quartile.
- Ein (1α) -Quantil heißt α -Fraktil.



Beweis

Sei c ein α -Fraktil des Wahrscheinlichkeitsmasses $P_0 \circ R^{-1}$. Definitionsgemäß gilt also $P_0(R \geq c) \geq \alpha$ und $P_0(R > c) = 1 - \underbrace{P_0(R \leq \alpha)} \leq \alpha$. Folglich gilt

$$\alpha - P_0(R > c) \le P_0(R \ge c) - P_0(R > c) = P_0(R = c).$$

Ist $P_0(R=c)=0$ so ist $P_0(R>c)=\alpha$ und $\varphi=1_{R>c}$ ein

Neyman-Pearson-Test mit $\mathbb{E}_0(\varphi) = \alpha$.

Ist
$$P_0(R=c) > 0$$
, so ist

$$\gamma := \frac{\alpha - P_0(R > c)}{P_0(R = c)} \in [0, 1]$$



Beweis

Damit ist

$$\varphi(x) = \begin{cases} 1 \text{ falls } R(x) > c \\ \gamma \text{ falls } R(x) = c \\ 0 \text{ falls } R(x) < c \end{cases}$$

ein Neyman-Pearson-Test mit

$$\mathbb{E}_0(\varphi) = P_0(R > c) + \gamma P_0(R = c) = \alpha.$$

Beweis

Sei φ ein Neyman-Pearson-Test mit $\mathbb{E}_0(\varphi)=\alpha$ und Schwellenwert c sowie ψ ein beliebiger Test zum Niveau α . Ist $\varphi(x)>\psi(x)$, so ist $\varphi(x)>0$, also $R(x)\geq c$ und daher $p_1(x)\geq cp_0(x)$. Ist $\varphi(x)<\psi(x)$ ist $\varphi(x)<1$ und also $p_1(x)\leq cp_0(x)$. Es gilt also immer

$$f_1(x) := (\varphi(x) - \psi(x))p_1(x) \ge c(\varphi(x) - \psi(x))p_0(x)) := c \ f_0(x)$$

Integration (bzw. Summation im diskreten Fall) liefert

$$\mathbb{E}_1(\varphi) - \mathbb{E}_1(\psi) = \int_{\mathcal{X}} f_1(x) dx \ge c \int_{\mathcal{X}} f_0(x) dx = c(\alpha - \mathbb{E}_0(\psi)) \ge 0$$

und damit ist φ ein bester Test.



Beweis

Ist ψ ein beliebiger bester Test, so gilt in obigen Ungleichungen überall Gleichheit und damit $\varphi=\psi$ fast überall (bis auf Nullmenge). Damit ist auch ψ ein Neumann-Pearson-Test.

Beispiel Entscheidungsfindung - Lösung

Im Beispiel der Orangenlieferung setzen wir $\Theta_0=\{0,\cdots \rho_0\}$ und $\Theta_1=\{\rho_0+1,\cdots N\}$ mit $\rho_0=500$ und betrachten den Test

$$\varphi(x) = \begin{cases} 1 \text{ falls } x > c \\ 0 \text{ falls } x \le c \end{cases}$$

zur Hypothese $H_0: \rho \in \Theta_0$ und der Alternative $H_1: \rho \in \Theta_1$. Wir möchten c nach Möglichkeit so bestimmen, dass der Test φ optimal ist. Wir wählen c als α -Fraktil von P_{ρ_0} . γ ergibt sich dann aus

$$G_{\varphi}(\rho_0) = P_{\rho_0}(\{c+1,\cdots,n\}) + \gamma P_{\rho_0}(\{c\}) = \alpha$$



Beispiel Entscheidungsfindung - Lösung

Für $\rho' > \rho$ ist der Likelyhood-Quotient $R_{\rho':\rho}(x) := \frac{P_{\rho'(x)}}{p_{\rho}(x)}$ monoton wachsend in x, da

$$R_{\rho':\rho}(x) = \prod_{k=\rho}^{\rho'-1} \frac{(k+1)(N-k-n+x)}{(N-k)(k+1-x)}$$

Setzen wir $\bar{c}:=R_{\rho':\rho}(c)$, dann gilt wegen der Monotonie: Ist $R_{\rho':\rho}(x)>\bar{c}$ so ist x>c und daher $\varphi(x)=1$. Im Fall $R_{\rho':\rho}(x)<\bar{c}$ ergibt sich ebenso $\varphi(x)=0$. φ is also ein Neyman-Pearson-Test der Nullhypothese $\{\rho\}$ gegen $\{\rho'\}$. Für $\rho=\rho_0$ und beliebiges $\rho'\in\Theta_1$ ist φ damit ein bester Test für die Hypothese $H_0:\rho=\rho_0$ gegen $H_1:\rho\in\Theta_1$ zum Niveau α .

Beispiel Entscheidungsfindung - Lösung

Wir müssen also noch zeigen, dass es auch ein bester Test für alle $\rho \in \Theta_0$ zum Niveau α ist. Da $G_{\varphi}(\rho) \leq \alpha$ für alle $\rho \in \Theta_0$ gelten muss und nach Konstruktion und $G_{\varphi}(\rho_0) = \alpha$, reicht zu zeigen, dass die Gütefunktion G_{φ} monoton wachsend ist. Für $\rho < \rho'$ ist φ ein bester Test zum Niveau $\beta = G_{\varphi}(\rho)$ und damit ist er besser als der konstante Test $\psi = \beta$. Es folgt $G_{\varphi}(\rho') \geq G_{\psi}(\rho') = \beta = G_{\varphi}(\rho)$ und damit ist die Gütefunktion wachsend.

Beispiel Entscheidungsfindung - Lösung

Es ergibt sich c = 6 und $\gamma = 0.52$.

Einseitiger Test mit monotonem Lieklyhood-Quotienten

Sei $(\mathcal{X}, \mathcal{F}, P_{\rho} : \rho \in \Theta \subset \mathbb{R})$ ein statistisches Modell mit Dichte p_{ρ} von P_{ρ} und wachsendem Likelyhood-Quotient $R_{\rho':\rho}(x) := \frac{p_{\rho'(x)}}{p_{\rho}(x)}$ bezüglich einer Statistik T (Dies bedeutet: $R_{\rho':\rho}(x) > f_{\rho',\rho} \circ T$ mit einer wachsenden Funktion $f_{\rho',\rho}$). Dann ist für einen Schwellenwert $\rho_0 \in \Theta$ und ein Niveau $0 < \alpha < 1$ der Test

$$\varphi(x) = \begin{cases} 1 \text{ falls } T(x) > c \\ \gamma \text{ falls } T(x) = c \\ 0 \text{ falls } T(x) < c \end{cases}$$

ein optimaler Test für die Nullhypothese $H_0: \rho \leq \rho_0$ gegen die Alternative $H_1: \rho > \rho_0$. c und γ lassen sich aus der Beziehung

$$G_{\varphi}(\rho_0) = \alpha \Leftrightarrow P_{\rho_0}(T > c) + \gamma P_{\rho_0}(T = c) = \alpha \tag{1}$$

bestimmen.

200

Beweis

Analog zu Beispiel mit Orangenlieferung!

Konkrete Bestimmung von c: Fall $P_{\rho_0}(T=c)=0$ (kontinuierlicher Fall)

Wähle $\rho_0=\max_{\rho}\rho\in\Theta_0$. Wegen Gleichung (1) muss dann $P_{\rho_0}(T>c)\leq \alpha$ gelten. Dies ist gleichbedeutend mit der Bedingung $P_{\rho_0}(T\leq c)\geq 1-\alpha$. Damit ist c gerade das $(1-\alpha)$ -Quantil (bzw. das α -Fraktil) der Verteilung des Schätzers $P_{T_{\rho_0}}$ bei fester Wahl des Parameters $\rho=\rho_0$. Kennt man diese Verteilung, kann man das $(1-\alpha)$ -Quantil und damit c in entsprechenden Tabellen einfach nachschlagen.

Konkrete Bestimmung von c: Fall $P_{\rho_0}(T=c) \neq 0$ (diskreter Fall)

Wähle $\rho_0 = \max_{\rho} \rho \in \Theta_0$. Da $\gamma \in [0,1]$ muss für $\gamma = 1$ wegen Gleichung (1) $P_{\rho_0}(T \geq c) \leq \alpha$ gelten. Dies ist gleichbedeutend mit der Bedingung $1 - P_{\rho_0}(T < c) \leq \alpha$. Wir müssen das kleinste c finden, so dass $1 - P_{\rho_0}(T \leq c - 1) \leq \alpha$ ist. Dies ist gleichbedeutend mit $P_{\rho_0}(T \leq c - 1) \geq 1 - \alpha$. Wir können damit c - 1 mit Hilfe einer Verteilungstabelle oder als $(1 - \alpha)$ -Quantil in einer Quantils-Tabelle der Verteilung des Schätzers $P_{T_{\rho_0}}$ bei fester Wahl des Parameters $\rho = \rho_0$ ermitteln.