

Wahrscheinlichkeitstheorie und Statistik (Stochastik)



Dr. rer. nat. Johannes Riesterer

Diskrete Wahrscheinlichkeitsverteilung

Beispiel: Hash Kollision

Beim Hashing werden zufällig k Daten auf n Speicherplätze verteilt. Bezeichnen wir mit $A_{k,n}$ die Möglichkeiten der Mehrfachbelegungen von Feldern, so ist das komplementäre Ereignis $A_{k,n}^c = \text{Var}_k^n(\Omega, o.W.)$, wobei Ω die Menge der verfügbaren Speicherplätze darstellt.




Figure: Quelle: Wikipedia

Beispiel: Hash Kollision

$$P(A_{k,n}^c) = \frac{\#Var_k^n(\Omega, o.W.)}{\#Var_k^n(\Omega, m.W.)} =$$


$$\frac{n_k}{n^k} = \frac{n \cdot (n-1) \cdots (n-(k-1))}{n^k} = \prod_{i=0}^{k-1} \left(1 - \frac{i}{n}\right)$$

$$= \exp\left(\sum_{i=0}^{k-1} \ln\left(1 - \frac{i}{n}\right)\right) \leq \exp\left(\sum_{i=0}^{k-1} \left(-\frac{i}{n}\right)\right)$$

$$(\ln(1-x) \leq -x \text{ für } x < 1)$$

$$= \exp\left(-\frac{(k-1)k}{2n}\right)$$

Diskrete Wahrscheinlichkeitsverteilung



Beispiel: Hash Kollision (Geburtstags-Paradoxon)

Für $n = 365$ und $k = 23$ ist damit $P(A_{k,n}) > \frac{1}{2}$. Die Wahrscheinlichkeit, dass bei einer Gruppe von mehr als 23 Leuten zwei Leute am gleichen Tag Geburtstag haben, ist also größer als $\frac{1}{2}$.

Satz der totalen Wahrscheinlichkeit

Für eine Zerlegung $\Omega = \bigcup_{j=1}^n B_j$, mit $B_i \cap B_k = \emptyset$ für $i \neq k$

$$P(A) = \sum_{j=1}^n P(A \mid B_j) \cdot P(B_j)$$

Beweis

Da $A = A \cap \Omega = A \cap \bigcup_{j=1}^n B_j = \bigcup_{j=1}^n (A \cap B_j)$ eine disjunkte Zerlegung ist, folgt:

$$P(A) = \sum_{j=1}^n P(A \cap B_j) = \sum_{j=1}^n P(A \mid B_j) \cdot P(B_j)$$

Satz von Bayes

Für $A, B \in \mathcal{A}$ mit $P(B) > 0$ gilt

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)}$$

Beweis

$$P(A | B) = \frac{P(A \cap B)}{P(B)} = \frac{\frac{P(A \cap B) \cdot P(A)}{P(A)}}{P(B)} = \frac{P(B | A) \cdot P(A)}{P(B)}$$

Das Ziegenproblem (Monty Hall)

Es gibt drei Türen. Hinter genau einer steht das Auto, hinter den beiden anderen je eine Ziege. Der Spieler wählt zunächst irgendeine der drei Türen. Danach öffnet der Moderator, der die Lage des Autos kennt, immer eine andere Tür mit Ziege. Anschließend darf der Spieler zur einzig verbleibenden geschlossenen Tür wechseln.

Abstrakte Ereignisse

Wir definieren

$A = \{\text{die erste Wahl des Spielers ist richtig}\},$

$W = \{\text{der Spieler gewinnt beim Wechseln}\}.$

Da genau eine von drei Türen das Auto enthält, gilt sofort

$$P(A) = \frac{1}{3}.$$

Rigoroser Beweis

Aus der Spielregel folgt unmittelbar

$$P(W \mid A) = 0, \quad P(W \mid A^c) = 1.$$

Denn im Fall A ist die erste Wahl bereits richtig, also verliert Wechseln. Im Fall A^c ist die erste Wahl falsch; der Moderator muss dann die einzige Ziegentür unter den beiden anderen öffnen, und die verbleibende geschlossene Tür enthält das Auto.

Schlussfolgerung mit bedingter Wahrscheinlichkeit

Mit dem Satz der totalen Wahrscheinlichkeit folgt

$$\begin{aligned}P(W) &= P(W \mid A)P(A) + P(W \mid A^c)P(A^c) \\&= 0 \cdot \frac{1}{3} + 1 \cdot \frac{2}{3} = \frac{2}{3}.\end{aligned}$$

Die Gewinnchance beim Bleiben ist dagegen

$$P(A) = \frac{1}{3}.$$

Also ist Wechseln optimal. Die genaue Auswahlregel des Moderators unter mehreren möglichen Ziegentüren ist dabei egal, solange er immer eine Ziegentür öffnet und Wechseln anbietet.

Bayes'sche Inferenz (Bayesian Inference)

Die Formel von Bayes beschreibt, wie wir eine Hypothese H nach Beobachtung von Daten D aktualisieren:

$$P(H \mid D) = \frac{P(D \mid H) \cdot P(H)}{P(D)}$$

Dabei heißen

$P(H)$

Prior,

$P(D \mid H)$

Likelihood,

$P(H \mid D)$

Posterior.

Diskrete Wahrscheinlichkeitsverteilung

Interpretation der Bayes'schen Inferenz

Wir starten mit einer anfänglichen Einschätzung $P(H)$ über eine Hypothese und passen diese durch neue Daten D an. Ist $P(D | H)$ groß, dann sprechen die Daten für die Hypothese; ist $P(D | H)$ klein, dann spricht das gegen sie.

Prior, Likelihood, Posterior

- | | |
|-------------------------|-------------------------------------|
| Prior $P(H)$: | unsere Einschätzung vor den Daten, |
| Likelihood $P(D H)$: | wie gut erklärt H die Daten D , |
| Posterior $P(H D)$: | unsere Einschätzung nach den Daten. |

Wichtig: Die Likelihood ist nicht $P(H | D)$, sondern $P(D | H)$. Sie bewertet also die Daten unter der Annahme, dass die Hypothese gilt.

Typischer Ablauf

- 1 Formuliere mögliche Hypothesen $H_1, \dots, H_k$.
- 2 Lege Prior-Wahrscheinlichkeiten $P(H_i)$ fest.
- 3 Modelliere die Datenwahrscheinlichkeit $P(D | H_i)$.
- 4 Berechne daraus die Posterior-Wahrscheinlichkeiten $P(H_i | D)$.
- 5 Entscheide z.B. mit der wahrscheinlichsten Hypothese (MAP-Regel).

Bayesianische Sicht

Wahrscheinlichkeit misst Unsicherheit. Darum dürfen auch Hypothesen oder Parameter Wahrscheinlichkeiten tragen:

$$P(H), \quad P(H \mid D), \\ p(\theta \mid x).$$

Neue Daten aktualisieren dieses Wissen durch Bayes.

Frequentistische Sicht

Wahrscheinlichkeit beschreibt relative Häufigkeiten. Ein Parameter θ ist fest; zufällig sind Daten, Schätzer, Tests und Intervalle.

Wissenschaftsphilosophische Differenz

Bayesianer fragen: “Wie plausibel ist eine Hypothese nach den Daten?” Frequentisten fragen: “Wie verhält sich ein Verfahren bei vielen Wiederholungen?”

Was ist zufällig?

Bayesianisch: Auch Hypothesen dürfen Wahrscheinlichkeiten tragen, zum Beispiel

$$P(H \mid D).$$

Frequentistisch: Eine Hypothese ist nicht zufällig, sondern entweder wahr oder falsch; zufällig sind nur die Daten und damit das statistische Verfahren.

Was bedeuten 95%?

Bayesianisch kann man sinnvoll sagen:

$$P(H \mid D) = 0.95.$$

Das bedeutet: Nach dem Modell und den beobachteten Daten hat die Hypothese H eine Plausibilität von 95%.

Diskrete Wahrscheinlichkeitsverteilung

Frequentistische Deutung von 95%

Frequentistisch bezieht sich 95% typischerweise auf ein Verfahren, also auf eine Fehlerquote oder Trefferquote bei vielen gedachten Wiederholungen.

Wichtige Folgerung

Ein frequentistisches Signifikanzniveau von 5% bedeutet daher nicht: "Die Nullhypothese ist mit Wahrscheinlichkeit 5% wahr." Gemeint ist vielmehr: Wenn die Nullhypothese wahr ist, produziert das Verfahren langfristig nur in etwa 5% der Fälle einen falschen Alarm.

Einordnung

Bayesianische Verfahren sind stark bei explizitem Vorwissen. Frequentistische Verfahren sind stark bei Fehlerkontrolle und Kalibrierung. Oft sind das zwei komplementäre Perspektiven.

Black-Swan-Paradoxon in bayesianischer Sicht

Sei $H = \{\text{alle Schwäne sind weiß}\}$,
 $D_n = \{\text{die ersten } n \text{ beobachteten Schwäne sind weiß}\}$ und
 $B = \{\text{ein beobachteter Schwan ist schwarz}\}$. Dann gilt nach Bayes

$$P(H \mid D_n) = \frac{P(D_n \mid H)P(H)}{P(D_n)}.$$

Unter H ist jede weiße Beobachtung sicher, also $P(D_n \mid H) = 1$. Weiße Schwäne sprechen daher für H , aber sie beweisen H nicht, weil auch andere Hypothesen viele weiße Schwäne gut erklären können.

Asymmetrie der Evidenz

Beobachten wir dagegen einen schwarzen Schwan B , so gilt unter H :

$$P(B \mid H) = 0.$$

Damit folgt sofort

$$P(H \mid B) = 0.$$

Viele bestätigende Beobachtungen machen eine All-Aussage also nur schrittweise plausibler; ein echtes Gegenbeispiel zerstört sie sofort.

Konkretes bayesianisches Beispiel

Vergleichen wir zwei Hypothesen mit gleichem Prior:

$$P(H) = P(H') = \frac{1}{2},$$

wobei

$H = \{\text{alle Schwäne sind weiß}\},$

$H' = \{95\% \text{ aller Schwäne sind weiß}\}.$

Dann gilt für n weiße Beobachtungen:

$$P(D_n | H) = 1, \quad P(D_n | H') = 0.95^n.$$

Posterior ausrechnen

Da wir nur die beiden Hypothesen H und H' zulassen, ist

$$P(D_n) = P(D_n | H)P(H) + P(D_n | H')P(H').$$

Mit Bayes folgt daher

$$\begin{aligned} P(H | D_n) &= \frac{P(D_n | H)P(H)}{P(D_n | H)P(H) + P(D_n | H')P(H')} \\ &= \frac{1 \cdot \frac{1}{2}}{1 \cdot \frac{1}{2} + 0.95^n \cdot \frac{1}{2}}. \end{aligned}$$

Im Zähler und Nenner kann man den gemeinsamen Faktor $\frac{1}{2}$ kürzen. Also

$$P(H | D_n) = \frac{1}{1 + 0.95^n}.$$

Bedeutung der Formel

Zum Beispiel:

$$P(H \mid D_{10}) \approx 0.625, \quad P(H \mid D_{100}) \approx 0.994.$$

Mit wachsendem n wird der Term 0.95^n immer kleiner. Damit fällt die Konkurrenzhypothese H' im Nenner immer weniger ins Gewicht. Viele weiße Schwäne machen H also sehr plausibel, aber nicht durch logische Notwendigkeit, sondern relativ zu den zugelassenen Konkurrenzhypothesen.

Philosophische Punkte

Bayesianisch ist das kein Widerspruch, sondern eine Folge von Likelihood und Prior. Die Daten allein erzeugen keine Theorie aus dem Nichts, sondern aktualisieren nur, was vorher als möglich modelliert war.

Induktion braucht Vorannahmen

Wenn der Prior $P(H) = 0$ wäre, dann bliebe für alle n

$$P(H \mid D_n) = 0.$$

Auch unendlich viele weiße Schwäne könnten H dann nie plausibel machen. Gerade darin zeigt sich die philosophische Tiefe: Induktives Lernen funktioniert nur relativ zu einem Modellraum und zu Vorannahmen.

Diskrete Wahrscheinlichkeitsverteilung

Beispiel: medizinischer Test

Sei H = "Person ist krank" und D = "Test ist positiv". Angenommen:

$$P(H) = 0.01,$$

$$P(D | H) = 0.99,$$

$$P(D | H^c) = 0.05.$$

Dann ist der Prior klein: Nur 1% der Personen sind krank. Die Likelihood $P(D | H) = 0.99$ sagt: Wenn jemand krank ist, ist der Test fast immer positiv.

Wichtig: $P(D | H)$ und $P(D | H^c)$ sind keine

Gegenwahrscheinlichkeiten, weil unterschiedlich konditioniert wird.

Komplementär wären hier zum Beispiel $P(D | H)$ und $P(D^c | H)$.

Posterior berechnen

Mit Bayes folgt

$$\begin{aligned} P(H | D) &= \frac{P(D | H)P(H)}{P(D | H)P(H) + P(D | H^c)P(H^c)} \\ &= \frac{0.99 \cdot 0.01}{0.99 \cdot 0.01 + 0.05 \cdot 0.99} \approx 0.167. \end{aligned}$$

Obwohl der Test gut ist, liegt die Wahrscheinlichkeit nach einem positiven Test also nur bei etwa 16.7%.

Bayes bei kontinuierlichen Verteilungen

Ist der unbekannte Parameter Θ selbst stetig verteilt, dann arbeiten wir mit Dichten statt mit einzelnen Wahrscheinlichkeiten. Für Prior-Dichte $p(\theta)$ und Likelihood-Dichte $f(x | \theta)$ gilt nach Beobachtung $X = x$:

$$p(\theta | x) = \frac{f(x | \theta) p(\theta)}{\int_{-\infty}^{\infty} f(x | u) p(u) du}.$$

Bei stetigen Verteilungen ist nämlich $P(X = x) = 0$; relevant ist daher die Dichte an der beobachteten Stelle x .

Diskrete Wahrscheinlichkeitsverteilung

Beispiel: Raumtemperatur und Thermometer

Sei Θ die wahre Raumtemperatur in Grad Celsius. Vor der Messung glauben wir, dass die Temperatur meistens in der Nähe von 20°C liegt:

$$\Theta \sim \mathcal{N}(20, 2^2).$$

Das Thermometer misst nicht perfekt, sondern mit einem Fehler von etwa 1°C . Also modellieren wir

$$X \mid \Theta = \theta \sim \mathcal{N}(\theta, 1^2).$$

Wenn das Thermometer nun $X = 24$ misst, dann ergibt sich als Posterior wieder eine Normalverteilung:

$$\Theta \mid X = 24 \sim \mathcal{N}(23.2, 0.8).$$

Interpretation

Der Prior sagt: Vor der Messung erwarten wir ungefähr 20°C . Die Likelihood sagt: Ein Messwert von 24°C ist besonders plausibel, wenn die wahre Temperatur in der Nähe von 24°C liegt. Der Posterior kombiniert beides: Nach der Messung halten wir Werte um 23.2°C für am plausibelsten.

Erinnerung Stochastische Unabhängigkeit

Zwei Ereignisse A, B heißen stochastisch unabhängig, falls

$$P(A \cap B) = P(A) \cdot P(B)$$

gilt. Gleichbedeutend damit ist $P(A|B) = P(A)$ und $P(B|A) = P(B)$.

Naiver Bayes'scher Spam Filter

Gegeben ist eine E-Mail E . Wir möchten anhand des Vorkommens bestimmter Wörter $A_1, \dots, A_n$ in der Mail entscheiden, ob es sich um eine erwünschte Mail H oder eine unerwünschte Mail S (Ham or Spam) handelt. (Typische Wörter wären zum Beispiel "reich", "casino", "Vergrößerung" ...)



Naiver Bayes'scher Spam Filter

Aus einer Datenbank kann man das Vorkommen dieser Wörter in Spam und Ham Mails zählen und damit empirisch die Wahrscheinlichkeiten $P(A_i|S)$ und $P(A_i|H)$ des Vorkommens dieser Wörter in Spam und Ham Mails ermitteln. Wir gehen davon aus, dass es sich bei der Mail prinzipiell mit Wahrscheinlichkeit $P(E = S) = P(E = H) = \frac{1}{2}$ um eine erwünschte Mail H oder eine unerwünschte Mail S handeln kann.

Naiver Bayes'scher Spam Filter

Wir machen zudem die (naive) Annahme, dass das Vorkommen der Wörter stochastisch unabhängig ist, also

$$P(A_1 \cap \dots \cap A_n | S) = P(A_1 | S) \cdot P(A_2 | S) \cdots P(A_n | S)$$
$$P(A_1 \cap \dots \cap A_n | H) = P(A_1 | H) \cdot P(A_2 | H) \cdots P(A_n | H)$$

gilt.

Naiver Bayes'scher Spam Filter

Mit der Formel von Bayes, der totalen Wahrscheinlichkeit und kürzen, da $P(S) = P(H)$ können wir somit berechnen

$$\begin{aligned} P(E = S | A_1 \cap \dots \cap A_n) &= \frac{P(A_1 \cap \dots \cap A_n | S) \cdot P(S)}{P(A_1 \cap \dots \cap A_n)} \\ &= \frac{P(A_1 | S) \cdots P(A_n | S)}{P(A_1 \cap \dots \cap A_n | H) + P(A_1 \cap \dots \cap A_n | S)} \\ &= \frac{P(A_1 | S) \cdots P(A_n | S)}{P(A_1 | H) \cdots P(A_n | H) + P(A_1 | S) \cdots P(A_n | S)} \end{aligned}$$

Bemerkung: $P(E = H | A_1 \cap \dots \cap A_n) = 1 - P(E = S | A_1 \cap \dots \cap A_n)$

Diskrete Wahrscheinlichkeitsverteilung

Spamfilter als Bayes'sche Inferenz

Der naive Bayes-Filter ist ein klassisches Beispiel für Bayes'sche Inferenz:

Hypothesen: $H = \text{Ham}$, $S = \text{Spam}$,

Daten: $D = A_1 \cap \dots \cap A_n$.

Aus Prior und Likelihoods berechnen wir die Posterior-Wahrscheinlichkeiten

$$P(S \mid D), \quad P(H \mid D).$$

Einordnung

- Prior: $P(S), P(H)$ beschreibt, wie wahrscheinlich Spam oder Ham vor den Wörtern ist.
- Likelihood: $P(D \mid S), P(D \mid H)$ misst, wie gut die beobachteten Wörter zu Spam oder Ham passen.
- Posterior: $P(S \mid D), P(H \mid D)$ kombiniert beides nach der Bayes-Formel.
- Entscheidung: Klassifiziere als Spam, falls $P(S \mid D) > P(H \mid D)$.

Eigenschaften

Sind $X, Y : \Omega \rightarrow \mathbb{R}^n$ reelle, integrierbare Zufallsvariablen und $a, b \in \mathbb{R}$ konstant, so gilt:

$$\mathbb{E}(a \cdot X + b \cdot Y) = a \cdot \mathbb{E}(X) + b \cdot \mathbb{E}(Y)$$

$$X(x) \leq Y(x) \quad \forall x \in \Omega \Rightarrow \mathbb{E}(X) \leq \mathbb{E}(Y)$$

$$X, Y \text{ stoch. unabhängig} \Rightarrow \mathbb{E}(X \cdot Y) = \mathbb{E}(X) \cdot \mathbb{E}(Y)$$

$$\mathbb{E}(1_A) = P(A)$$

Verschiebungssatz (Erwartungswert)

Sei $X : \Omega \rightarrow \mathbb{R}$ eine reelle Zufallsvariable und $g : \mathbb{R} \rightarrow \mathbb{R}$ messbar.
Dann gilt:

$$\mathbb{E}(g(X)) = \int_{\mathbb{R}} g(x) dP_X(x)$$

wobei P_X die Verteilung von X ist. Für eine Dichte f_X :

$$\mathbb{E}(g(X)) = \int_{\mathbb{R}} g(x) f_X(x) dx$$

Man muss also **nicht** die Verteilung von $g(X)$ bestimmen, sondern kann direkt mit der Verteilung von X rechnen.

Beweis des Verschiebungssatzes (Schritt 1: Indikatorfunktionen)

Für $g = 1_B$ mit einer Borel-Menge $B \subseteq \mathbb{R}$:

$$\mathbb{E}(1_B(X)) = P(X \in B) = P_X(B) = \int_{\mathbb{R}} 1_B(x) dP_X(x) \quad \checkmark$$

Dies folgt direkt aus der Definition des Bildmaßes $P_X(B) = P(X^{-1}(B))$.

Beweis (Schritt 2: Einfache Funktionen)

Für $g = \sum_{i=1}^n a_i \cdot 1_{B_i}$ folgt aus Schritt 1 und der Linearität des Integrals:

$$\mathbb{E}(g(X)) = \sum_{i=1}^n a_i P_X(B_i) = \int_{\mathbb{R}} g(x) dP_X(x)$$

Beweis (Schritt 3: Allgemeine messbare $g \geq 0$)

Es existieren einfache Funktionen $g_n \nearrow g$ (monoton wachsend).
Mit dem Satz der monotonen Konvergenz:

$$\mathbb{E}(g(X)) = \lim_n \mathbb{E}(g_n(X)) \stackrel{\text{Schritt 2}}{=} \lim_n \int g_n dP_X = \int g dP_X$$

Beweis (Schritt 4: Allgemeines g)

Zerlege $g = g^+ - g^-$ mit $g^+ = \max(g, 0)$ und $g^- = \max(-g, 0)$.
Wende Schritt 3 auf g^+ und g^- an und nutze die Linearität. $\square$

Varianz

Für eine reelle Zufallsvariable ist die Varianz definiert durch

$$\mathbb{V}(X) := \mathbb{E}((X - \mathbb{E}(X))^2) .$$

Verschiebungssatz

$$\begin{aligned}\mathbb{V}(X) &= \mathbb{E}(X^2 - 2X\mathbb{E}(X) + \mathbb{E}(X)^2) = \mathbb{E}(X^2) - 2\mathbb{E}(X)^2 + \mathbb{E}(X)^2 \\ &= \mathbb{E}(X^2) - \mathbb{E}(X)^2\end{aligned}$$

Eigenschaften der Varianz

Sind $X, Y : \Omega \rightarrow \mathbb{R}$ reelle, quadratintegrierbare Zufallsvariablen und $a, b \in \mathbb{R}$ konstant, so gilt:

$$\mathbb{V}(a \cdot X + b) = a^2 \cdot \mathbb{V}(X)$$

$$\mathbb{V}(X) \geq 0, \quad \mathbb{V}(X) = 0 \Leftrightarrow X = \mathbb{E}(X) \text{ f.s.}$$

$$X, Y \text{ stoch. unabhängig} \Rightarrow \mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y)$$

$$\mathbb{V}(X + Y) = \mathbb{V}(X) + \mathbb{V}(Y) + 2\mathcal{C}(X, Y) \quad (\text{allgemein})$$

Kovarianz

Für reelle Zufallsvariable X, Y ist die Kovarianz definiert durch

$$\mathcal{C}(X, Y) := \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y))) .$$

Kovarianz

Per Definition ist

$$\mathcal{C}(X, X) := \mathbb{V}(X).$$

Beispiel

$\Omega = \{\text{Kopf}, \text{Zahl}\}, P(\text{Kopf}) = P(\text{Zahl}) = \frac{1}{2},$
 $X(\text{Kopf}) = 0, X(\text{Zahl}) = 1$

$$\begin{aligned}\mathbb{E}(X) &= 0 \cdot P(X^{-1}(0)) + 1 \cdot P(X^{-1}(1)) \\ &= 0 \cdot P(\text{Kopf}) + 1 \cdot P(\text{Zahl}) = \frac{1}{2}\end{aligned}$$

Beispiel

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$.

$$\begin{aligned}\mathbb{E}(X) &:= \int_{\mathbb{R}} x \cdot \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} dx \\&= \int_{\mathbb{R}} (y + \mu) \cdot \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}y^2} dy \\&= \mu \int_{\mathbb{R}} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}y^2} dy + \int_{\mathbb{R}} y \cdot \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}y^2} dy = \mu\end{aligned}$$




Figure: Quelle: Wikipedia

Beispiel

Sei $X \sim \mathcal{N}(\mu, \sigma^2)$.

$$\begin{aligned}\mathbb{V}(X) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^2 e^{-\frac{x^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x(xe^{-\frac{x^2}{2}}) dx \\ &= \frac{1}{\sqrt{2\pi}} \left(\left[x(e^{-\frac{x^2}{2}}) \right]_{-\infty}^{\infty} - \int_{-\infty}^{\infty} -e^{-\frac{x^2}{2}} dx \right) = 0 + 1 = 1\end{aligned}$$

[LINK: Partielle Integration](#). Mit "Verschiebungstrick"

$\Rightarrow \mathbb{V}(X) = \sigma^2$.

Markov Ungleichung

Sei $Y : \Omega \rightarrow \mathbb{R}$ eine reelle, integrierbare Zufallsvariable und $f : [0, \infty) \rightarrow [0, \infty)$ monoton wachsend. Dann gilt für alle $\epsilon > 0$ mit $f(\epsilon) > 0$

$$P(|Y| \geq \epsilon) \leq \frac{\mathbb{E}(f \circ |Y|)}{f(\epsilon)}$$

Beweis

Da $f(\epsilon)1_{\{|Y| \geq \epsilon\}} \leq f \circ |Y|$ folgt

$$\begin{aligned} f(\epsilon)P(|Y| \geq \epsilon) &= f(\epsilon)\mathbb{E}(1_{\{|Y| \geq \epsilon\}}) = \mathbb{E}(f(\epsilon)1_{\{|Y| \geq \epsilon\}}) \\ &\leq \mathbb{E}(f \circ |Y|) \end{aligned}$$

Tschebyscheff-Ungleichung

Für eine reelle, integrierbare und quadratintegrierbare Zufallsvariable $Y : \Omega \rightarrow \mathbb{R}$ gilt:

$$P(|Y - \mathbb{E}(Y)| \geq \epsilon) \leq \frac{\mathbb{V}(Y)}{\epsilon^2}$$

Beweis

Folgt direkt aus der Markov-Ungleichung mit $Y' = Y - \mathbb{E}(Y)$ und $f(x) = x^2$

Schwaches Gesetz der großen Zahlen

Seien $X_i : \Omega \rightarrow \mathbb{R}$ unabhängige, reelle Zufallsvariablen (uiv, iid(englisch)) mit $\mathbb{E}(X_i) = \mu < \infty$ und $\mathbb{V}(X_i) = \sigma < \infty$, dann gilt

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| \geq \epsilon\right) \leq \frac{\sigma}{n \cdot \epsilon^2} \xrightarrow{n \rightarrow \infty} 0$$

(stochastische Konvergenz).

Beweis

Mit $Y_n = \frac{1}{n} \sum_{i=1}^n X_i - \mu$ ist $\mathbb{E}(Y_n) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i - \mu) = 0$ und $\mathbb{V}(Y_n) = \frac{1}{n^2} \sum_{i=1}^n \mathbb{V}(X_i) = \frac{\sigma}{n}$. Aus der Tschebyscheff-Ungleichung folgt die Behauptung.

Erwartungswert

