

Stochastik für Informatiker



Dr. rer. nat. Johannes Riesterer

Erraten des Bereichs von Zufallsvariablen

Angenommen man findet einen Apparat (Fluxkompensator?), der zufällig Zahlen in einem Intervall $[0, \rho]$ ausgibt. Anhand von Beobachtungen der Zahlen möchte man ρ schätzen.



Figure: Quelle: forevergeek

Erraten des Bereichs von Zufallsvariablen - Modell

Wir machen die Annahme, dass alle Zahlen in dem Intervall gleich wahrscheinlich auftreten und nehmen n Stichproben $X_1, \dots, X_n$.
Einen Schätzer für ρ bezeichnen wir mit T_n .

Erraten des Bereichs von Zufallsvariablen - Schätzer 1

Eine einfache und einleuchtende Idee ist es, ρ durch die größte beobachtete Zahl zu schätzen, also $T_n^{\max} := \max(X_1, \dots, X_n)$.

Erraten des Bereichs von Zufallsvariablen - Schätzer 2

Da das Auftreten der Zahlen gleich wahrscheinlich ist, ist der Erwartungswert des Zufallsexperiments $\rho/2$. Unter Berufung auf das schwache Gesetz der Großen Zahlen erscheint der Schätzer $T_n^E := 2 \cdot \left(\frac{1}{n} \sum_{i=1}^n X_i \right)$ sehr plausibel.

Erraten des Bereichs von Zufallsvariablen - Vergleich

Welcher Schätzer ist besser und in welchem Sinn?

Erraten des Bereichs von Zufallsvariablen - Vergleich Konvergenz

T_n^{max}

$$\begin{aligned} &P(|T_n^{max} - \rho| \geq \epsilon) \\ &= P(T_n^{max} \leq \rho - \epsilon \text{ oder } T_n^{max} \geq \rho + \epsilon) \\ &= P(T_n^{max} \leq \rho - \epsilon) + \underbrace{P(T_n^{max} \geq \rho + \epsilon)}_{= 0, \text{ da } T_n^{max} \leq \rho} \end{aligned}$$

Erraten des Bereichs von Zufallsvariablen - Vergleich Konvergenz T_n^{max} (Forts.)

$$= P(T_n^{max} \leq \rho - \epsilon)$$

$$= P(X_1 \leq \rho - \epsilon, \dots, X_n \leq \rho - \epsilon) = \left(\frac{\rho - \epsilon}{\rho}\right)^n \xrightarrow[n \rightarrow \infty]{} 0$$

Erraten des Bereichs von Zufallsvariablen - Vergleich Konvergenz T_n^E

$$P(|T_n^E - \rho| \geq \epsilon) = P\left(\left|\frac{1}{n} \sum X_i - \frac{\rho}{2}\right| \geq \frac{\epsilon}{2}\right) \xrightarrow[n \rightarrow \infty]{} 0$$

(Gesetz der Großen Zahlen)

Verteilungsfunktion von T_n^{max}

Da die X_i u.i.v. und gleichverteilt auf $[0, \rho]$ sind, gilt für $0 \leq c \leq \rho$:

$$\begin{aligned} P(T_n^{max} \leq c) &= P(\max(X_1, \dots, X_n) \leq c) \\ &= P(X_1 \leq c, \dots, X_n \leq c) \\ &\stackrel{\text{u.i.v.}}{=} \prod_{i=1}^n P(X_i \leq c) = \left(\frac{c}{\rho}\right)^n \end{aligned}$$

Dichte und Erwartungswert von T_n^{max}

Die Dichte ergibt sich als Ableitung der Verteilungsfunktion:

$$f_{T_n^{max}}(x) = \frac{d}{dx} \left(\frac{x}{\rho} \right)^n = \frac{n}{\rho^n} x^{n-1}. \text{ Damit:}$$

$$\mathbb{E}(T_n^{max}) = \int_0^\rho x \cdot \frac{n}{\rho^n} x^{n-1} dx = \frac{n}{\rho^n} \int_0^\rho x^n dx = \frac{n}{n+1} \rho \xrightarrow{n \rightarrow \infty} \rho$$

Erwartungswert von T_n^E

$$\mathbb{E}(T_n^E) = \frac{2}{n} \sum \mathbb{E}(X_i) = \rho$$

Erraten des Bereichs von Zufallsvariablen - Vergleich Varianz

$$\mathbb{V}(T_n^E) = \frac{4}{n} \mathbb{V}(X_1) = \frac{4}{n\rho} \int_0^\rho \left(x - \frac{\rho}{2}\right)^2 dx = \frac{\rho^2}{3n}$$

Erraten des Bereichs von Zufallsvariablen - Vergleich Varianz

$$\begin{aligned} \mathbb{V}(T_n^{\max}) &= \mathbb{E}((T_n^{\max})^2) - (\mathbb{E}(T_n^{\max}))^2 \\ &= \int_0^\rho x^2 \frac{n}{\rho^n} x^{n-1} dx - \left(\frac{n\rho}{n+1}\right)^2 = \frac{n\rho^2}{(n+1)^2(n+2)} \end{aligned}$$

Statistisches Modell

Ein statistisches Modell ist ein Tripel $(\mathcal{X}, \mathcal{F}, P_\rho : \rho \in \Theta)$ bestehend aus einer σ -Algebra $\mathcal{F}$ über dem Grundraum $\mathcal{X}$ und einer indizierten Menge (mit mindestens zwei Elementen) von Maßen $\{P_\rho\}_{\rho \in \Theta}$. Für $\Theta \subset \mathbb{R}^n$ bezeichnet man es auch als parametrisiertes statistisches Modell.

Beispiel: Fluxkompensator

- $\mathcal{X} = [0, \rho]^n$ (Raum aller möglichen n -Stichproben)
- $\mathcal{F} = \mathcal{B}([0, \rho]^n)$ (Borel- σ -Algebra)
- $P_\rho = \mathcal{U}([0, \rho])^{\otimes n}$ (n -faches Produkt der Gleichverteilung)
- $\Theta = (0, \infty)$ (der unbekannte Parameter ρ)

Statistik

Sei $(\mathcal{X}, \mathcal{F}, P_\rho : \rho \in \Theta)$ ein statistisches Modell und $(\Sigma, \mathcal{G})$ eine σ -Algebra über Σ . Eine Zufallsvariable

$$X : \mathcal{X} \rightarrow \Sigma$$

wird Statistik für $(\mathcal{X}, \mathcal{F}, P_\rho : \rho \in \Theta)$ genannt.

Schätzer

Sei $(\mathcal{X}, \mathcal{F}, P_\rho : \rho \in \Theta)$ ein statistisches Modell, $(\Sigma, \mathcal{G})$ eine σ -Algebra über Σ und

$$\tau : \Theta \rightarrow \Sigma$$

$$\rho \mapsto \tau(\rho)$$

eine Abbildung. Eine Statistik $T : \mathcal{X} \rightarrow \Sigma$ wird Schätzer für τ genannt.

Beispiel: Fluxkompensator

- Zielraum: $\Sigma = (0, \infty)$, zu schätzende Abbildung: $\tau(\rho) = \rho$ (Identität)
- $T_n^{\max}(x_1, \dots, x_n) = \max(x_1, \dots, x_n)$ ist ein Schätzer für τ
- $T_n^E(x_1, \dots, x_n) = \frac{2}{n} \sum_{i=1}^n x_i$ ist ein Schätzer für τ

Konsistenz

Eine Schätzfolge $T_n : \mathcal{X} \rightarrow \Sigma$ heißt konsistent, falls

$$P(|T_n - \tau(\rho)| \geq \epsilon) \xrightarrow{n \rightarrow \infty} 0 \text{ für alle } \epsilon > 0 \text{ und alle } \rho \in \Theta$$

also $T_n \rightarrow \tau(\rho)$ für $n \rightarrow \infty$ (stochastisch).

Erwartungstreue

Ein Schätzer $T : \mathcal{X} \rightarrow \Sigma$ heißt Erwartungstreu (unbiased), falls

$$\mathbb{E}(T) = \tau(\rho) \text{ für alle } \rho \in \Theta.$$

Andernfalls heißt $\mathbb{E}(T) - \tau(\rho)$ der Bias oder der systematische Fehler.

Beispiel: Fluxkompensator – Konsistenz und Erwartungstreue

- T_n^{max} ist konsistent: $P(|T_n^{max} - \rho| \geq \epsilon) = \left(\frac{\rho - \epsilon}{\rho}\right)^n \rightarrow 0$
- T_n^{max} ist **nicht** erwartungstreu: $\mathbb{E}(T_n^{max}) = \frac{n}{n+1}\rho \neq \rho$
- T_n^{max} ist jedoch **asymptotisch erwartungstreu**:
$$\mathbb{E}(T_n^{max}) = \frac{n}{n+1}\rho \xrightarrow{n \rightarrow \infty} \rho$$
- T_n^E ist konsistent (nach GGZ)
- T_n^E ist erwartungstreu: $\mathbb{E}(T_n^E) = \rho$

Stichprobenmittel und Stichprobenvarianz

- Für $n \geq 2$ sei $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), P_\rho^n := \prod (P_\rho)_i)$ das Produktmodell
- $X_i(x_1, \dots, x_n) = x_i$ die Projektion auf die i -te Koordinate
- $m(\rho) = \mathbb{E}(X_i)$ so wie $v(\rho) = \mathbb{V}(X_i)$.
- $M = \frac{1}{n} \sum_{i=1}^n X_i$ Stichprobenmittel und
 $V = \frac{1}{n-1} \sum_{i=1}^n (X_i - M)^2$ Stichprobenvarianz.

Dann sind M und V erwartungstreue Schätzer für $m :=$ bzw. v .

Beweis

Sei $\rho \in \Theta$ fest. Wegen Linearität des EW und u.i.v. ist
 $\mathbb{E}(M) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = m(\rho)$.

Beweis

Aus Linearität des EW und $\mathbb{E}(X_i - M) = 0$, u.i.v, stochastische Unabhängigkeit folgt

$$\begin{aligned}(n-1)\mathbb{E}(V) &= \sum_{i=1}^n \mathbb{V}(X_i - M) \\ &= n\mathbb{V}\left(\frac{n-1}{n}X_1 - \frac{1}{n}\sum_{j=2}^n X_j\right) \\ &= n\left(\left(\frac{n-1}{n}\right)^2 + (n-1)\frac{1}{n^2}\right)v(\rho) = (n-1)v(\rho)\end{aligned}$$

Durch Teilen beider Seiten durch $n-1$ folgt die Behauptung.

Likelihood Funktion

Für eine parametrisierte Dichte $p_\rho : \mathcal{X} \rightarrow [0, 1]$ heißt

$$p_x : \Theta \rightarrow [0, 1]$$

$$p_x(\rho) := p(x, \rho)$$

die Likelihood Funktion zum Beobachtungswert $x \in \mathcal{X}$.

Maximum Likelihood Schätzer

Ein Schätzer $T : \mathcal{X} \rightarrow \Sigma$ heißt Maximum-Likelihood-Schätzer bezüglich des Beobachtungswerte $x \in \mathcal{X}$, falls

$$p_x(T(x)) = \max_{\rho \in \Theta} p_x(\rho)$$

also der Schätzwert $T(x)$ eine Maximalstelle der Funktion p_x auf Θ ist.

Intuition: Maximum Likelihood

Idee: Wähle den Parameter ρ , unter dem die beobachteten Daten x am **wahrscheinlichsten** sind.

- $x = (x_1, \dots, x_n) \in \mathcal{X}$ ist die **konkrete Stichprobe** (beobachtete Daten, fest)
- Die Dichte $p_\rho(x)$ gibt an, wie “plausibel” die Beobachtung x unter dem Parameter ρ ist
- Beim ML-Schätzer vertauschen wir die Perspektive: Wir fixieren x und variieren ρ
- Gesucht ist das ρ , das $p_x(\rho) = p(x, \rho)$ maximiert

Stichproben in der formalen Sprache

- $\mathcal{X} = \mathbb{R}^n$: Stichprobenraum (alle möglichen Beobachtungen)
- $X_i : \mathcal{X} \rightarrow \mathbb{R}$: Zufallsvariable (Projektion auf i -te Koordinate)
- $x = (x_1, \dots, x_n) \in \mathcal{X}$: konkrete **Realisierung** = Stichprobe

Wichtig: In $p_x(\rho)$ ist x **fest** (schon beobachtet). Nur ρ wird variiert – deshalb ist p_x eine Funktion von ρ allein.

Maximum Likelihood – Erklärung

Äquivalente Schreibweise: $T(x) \in \arg \max_{\rho \in \Theta} p_x(\rho)$

$\arg \max$ einer Funktion $f : A \rightarrow \mathbb{R}$ ist der **Eingabewert**, bei dem f ihr Maximum annimmt:

$$\arg \max_{a \in A} f(a) = \{a \in A : f(a) \geq f(a') \text{ für alle } a' \in A\}$$

Maximum Likelihood – Produkt, nicht Summe

Für u.i.v. Stichproben $x = (x_1, \dots, x_n)$ ist die Likelihood das **Produkt** der Einzeldichten (wegen Unabhängigkeit):

$$p_x(\rho) = \prod_{i=1}^n p_\rho(x_i)$$

Man sucht das ρ , das dieses Produkt maximiert.

ML-Schätzer: Kompromiss über alle Datenpunkte

Beispiel: $X_1, X_2 \sim N(m, 1)$, beobachtet: $x_1 = 2$, $x_2 = 8$.

- $m = 2$: $p_m(x_1)$ groß, $p_m(x_2)$ winzig $\Rightarrow$ Produkt klein
- $m = 8$: $p_m(x_2)$ groß, $p_m(x_1)$ winzig $\Rightarrow$ Produkt klein
- $m = 5$: beide moderat $\Rightarrow$ **Produkt maximal**

Der ML-Schätzer findet den **besten Kompromiss** über alle Datenpunkte – nicht den besten Parameter für einen einzelnen Wert.

ML bei abhängigen Daten

Im allgemeinen Fall (ohne Unabhängigkeit) gilt die Kettenregel:

$$p_{\rho}(x_1, \dots, x_n) = p_{\rho}(x_1) \cdot p_{\rho}(x_2 \mid x_1) \cdot p_{\rho}(x_3 \mid x_1, x_2) \cdots$$

Bei Unabhängigkeit vereinfacht sich $p_{\rho}(x_i \mid x_1, \dots, x_{i-1}) = p_{\rho}(x_i)$ und man erhält das Produkt.

Interpretation

- Unabhängig: “Wie wahrscheinlich ist jeder Wert einzeln?”
- Abhängig: “Wie wahrscheinlich ist dieser Wert, **gegeben** die vorherigen?”

In dieser Vorlesung arbeiten wir stets mit u.i.v., also reicht das Produkt.

Erraten des Bereichs – Likelihood-Funktion

Die X_i sind u.i.v. gleichverteilt auf $[0, \rho]$ mit Dichte $\frac{1}{\rho}$. Für eine Stichprobe $x = (x_1, \dots, x_n)$:

$$p_x(\rho) = \prod_{i=1}^n \frac{1}{\rho} \cdot \mathbf{1}_{[0, \rho]}(x_i) = \begin{cases} \frac{1}{\rho^n} & \text{falls } x_1, \dots, x_n \leq \rho \\ 0 & \text{sonst} \end{cases}$$

Erraten des Bereichs – Maximierung

- $p_x(\rho) = 0$ für $\rho < \max(x_1, \dots, x_n)$ (Daten wären unmöglich)
- $p_x(\rho) = \frac{1}{\rho^n}$ für $\rho \geq \max(x_1, \dots, x_n)$ (fällt monoton in ρ)
- Maximum bei kleinstem zulässigem ρ :

$$T_n^{\max}(x) = \max(x_1, \dots, x_n)$$

Physikalische Messung - Maximum Likelihood-Schätzer

Gegeben ist ein Sensor mit einer unbekannten Messgenauigkeit. Wir nehmen deshalb an, dass die Messung des Sensors einer Normalverteilung folgt, wobei der Erwartungswert (Messwert) und die Varianz (Streuung um Messwert) unbekannt sind. Wir machen n unabhängige Messungen und erhalten damit das Normalverteilte Produktmodell $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n), \prod_{i=1}^n N(m, v) : m \in \mathbb{R}, v > 0)$.

Physikalische Messung - Maximum Likelihood-Schätzer

Die Likelihood-Funktion ist gegeben durch

$$p_x(\rho) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi v}} e^{-\frac{(x_i - m)^2}{2v}} = \frac{1}{\sqrt{2\pi v}} e^{-\sum_{i=1}^n \left(\frac{(x_i - m)^2}{2v}\right)}$$

mit $x = (x_1, \dots, x_n)$ und $\rho = (m, v)$.

Physikalische Messung - Maximum Likelihood-Schätzer

Um diesen Ausdruck zu maximieren, muss m so gewählt werden, dass die quadratische Fehlersumme $\sum_{i=1}^n (x_i - m)^2$ minimal wird. Das ist der Fall für $m = M(x) = \frac{1}{n} \sum_{i=1}^n x_i$.

Physikalische Messung - Maximum Likelihood-Schätzer

Des weiteren muss v so gewählt werden, dass

$\frac{1}{\sqrt{2\pi v}} e^{-\sum_{i=1}^n \left(\frac{(x_i - M(x))^2}{2v} \right)}$ maximal wird. Differenziert man den Logarithmus dieses Ausdrucks nach v , erhalten wir

$$\begin{aligned} & -\frac{d}{dv} \left(\frac{n}{2} \log(v) + \frac{1}{2v} \sum_{i=1}^n (x_i - M(x))^2 \right) \\ &= -\frac{n}{2v} + \frac{1}{2v^2} \sum_{i=1}^n (x_i - M(x))^2 \end{aligned}$$

Dieser Term ist maximal, falls der letzte Term verschwindet. Dies ist er Fall für $v = V(x) = \frac{1}{n} \sum_{i=1}^n (x_i - M(x))^2$