

Wahrscheinlichkeitstheorie und Statistik (Stochastik) Markov-Ketten

Dr. rer. nat. Johannes Riesterer

Idee

Viele Prozesse in der Informatik und im Alltag können als Folge von Zuständen modelliert werden, bei denen der nächste Zustand nur vom aktuellen Zustand abhängt – nicht von der gesamten Vergangenheit.

Idee

Viele Prozesse in der Informatik und im Alltag können als Folge von Zuständen modelliert werden, bei denen der nächste Zustand nur vom aktuellen Zustand abhängt – nicht von der gesamten Vergangenheit.

Beispiele

- Websurfen: Die nächste Seite hängt nur von der aktuellen Seite ab (PageRank).
- Wetter: Morgen Regen/Sonne hängt (vereinfacht) nur vom heutigen Wetter ab.
- Warteschlangen: Anzahl der Kunden hängt nur vom aktuellen Zustand ab.

Definition (Stochastische Matrix)

Eine Matrix $P = (p_{ij})_{i,j \in S}$ mit Zustandsraum S heißt **stochastische Matrix**, falls:

- 1 $p_{ij} \geq 0$ für alle $i, j \in S$
- 2 $\sum_{j \in S} p_{ij} = 1$ für alle $i \in S$ (Zeilensumme = 1)

Definition (Stochastische Matrix)

Eine Matrix $P = (p_{ij})_{i,j \in S}$ mit Zustandsraum S heißt **stochastische Matrix**, falls:

- 1 $p_{ij} \geq 0$ für alle $i, j \in S$
- 2 $\sum_{j \in S} p_{ij} = 1$ für alle $i \in S$ (Zeilensumme = 1)

Interpretation

p_{ij} ist die Wahrscheinlichkeit, vom Zustand i in den Zustand j zu wechseln.

Formalisierung in Lean 4 / Mathlib

```
abbrev S (N : Nat) := Fin N
```

```
def IsTransitionMatrix (P : S N -> S N -> Real) : Prop :=  
  (forall x y, 0 <= P x y) /\  
  (forall x, (Sum y, P x y) = 1)
```

Formalisierung in Lean 4 / Mathlib

```
abbrev S (N : Nat) := Fin N
```

```
def IsTransitionMatrix (P : S N -> S N -> Real) : Prop :=  
  (forall x y, 0 <= P x y) /\  
  (forall x, (Sum y, P x y) = 1)
```

Korrespondenz


$$\begin{array}{ll} S = \{1, \dots, N\} & \longleftrightarrow \text{Fin } N \\ p_{ij} \geq 0 & \longleftrightarrow \forall x \ y, 0 \leq P \ x \ y \\ \sum_j p_{ij} = 1 & \longleftrightarrow \forall x, \left(\sum y, P \ x \ y \right) = 1 \end{array}$$

Markov-Ketten

Beispiel: Wetter mit 2 Zuständen

Zustandsraum

$$S = \{S(\text{onne}), R(\text{egen})\}$$



Übergangsmatrix

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$$

Zeile 1: Wenn heute Sonne, dann morgen Sonne mit 0.8, Regen mit 0.2.

Konkrete Definition in Lean

```
def weatherP : S 2 -> S 2 -> Real
| <0, _>, <0, _> => 0.8
| <0, _>, <1, _> => 0.2
| <1, _>, <0, _> => 0.4
| <1, _>, <1, _> => 0.6
```

Konkrete Definition in Lean

```
def weatherP : S 2 -> S 2 -> Real
| <0, _>, <0, _> => 0.8
| <0, _>, <1, _> => 0.2
| <1, _>, <0, _> => 0.4
| <1, _>, <1, _> => 0.6
```

Beweis: weatherP ist stochastische Matrix

```
lemma weatherP_isTransition :
  IsTransitionMatrix weatherP := by
  constructor
  . intro x y
    fin_cases x <;> fin_cases y <;>
    simp [weatherP] <;> norm_num
  . intro x
    fin_cases x <;> simp [weatherP] <;> norm_num
```

Definition (Markov-Kette)

Eine Folge von Zufallsvariablen $(X_n)_{n \in \mathbb{N}_0}$ mit Werten in einem abzählbaren Zustandsraum S heißt **Markov-Kette** mit Übergangsmatrix P , falls:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i) =$$

für alle $n \in \mathbb{N}_0$ und alle $i, j, i_0, \dots, i_{n-1} \in S$.

Definition (Markov-Kette)

Eine Folge von Zufallsvariablen $(X_n)_{n \in \mathbb{N}_0}$ mit Werten in einem abzählbaren Zustandsraum S heißt **Markov-Kette** mit Übergangsmatrix P , falls:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i) =$$

für alle $n \in \mathbb{N}_0$ und alle $i, j, i_0, \dots, i_{n-1} \in S$.

Markov-Eigenschaft (Gedächtnislosigkeit)

Die Zukunft hängt nur von der Gegenwart ab, nicht von der Vergangenheit!

Formalisierung über bedingte Erwartung

```
noncomputable def stepOp (P : S N -> S N -> Real)
  (f : S N -> Real) : S N -> Real :=
  fun x => Sum y, P x y * f y

def IsHomogeneousMarkov (mu : Measure Omega)
  (F : Filtration Nat _) (X : Nat -> Omega -> S N)
  (P : S N -> S N -> Real) : Prop :=
  Adapted F X /\
  forall n (f : S N -> Real), Measurable f ->
  mu[fun w => f (X (n+1) w) | F n] = a.e. [mu]
  fun w => stepOp P f (X n w)
```

Formalisierung über bedingte Erwartung

```
noncomputable def stepOp (P : S N -> S N -> Real)
  (f : S N -> Real) : S N -> Real :=
  fun x => Sum y, P x y * f y

def IsHomogeneousMarkov (mu : Measure Omega)
  (F : Filtration Nat _) (X : Nat -> Omega -> S N)
  (P : S N -> S N -> Real) : Prop :=
  Adapted F X /\
  forall n (f : S N -> Real), Measurable f ->
    mu[fun w => f (X (n+1) w) | F n] = a.e.[mu]
    fun w => stepOp P f (X n w)
```

Bedeutung

$\mathbb{E}[f(X_{n+1}) | \mathcal{F}_n] = (Pf)(X_n)$ fast sicher.


Dies ist die maßtheoretische Version der Markov-Eigenschaft.

Markov-Ketten

Beispiel: 3 Zustände (Stimmung)

Modell

$S = \{G(\text{ut}), N(\text{eutral}), S(\text{chlecht})\}$



$$P = \begin{pmatrix} 0.5 & 0.4 & 0.1 \\ 0.3 & 0.4 & 0.3 \\ 0.2 & 0.3 & 0.5 \end{pmatrix}$$

Satz (Chapman-Kolmogorov)

Die Wahrscheinlichkeit, in n Schritten von i nach j zu gelangen, ist:

$$p_{ij}^{(n)} = \mathbb{P}(X_n = j \mid X_0 = i) = (P^n)_{ij}$$

Also: Einfach die Matrix n -mal mit sich selbst multiplizieren!

Satz (Chapman-Kolmogorov)

Die Wahrscheinlichkeit, in n Schritten von i nach j zu gelangen, ist:

$$p_{ij}^{(n)} = \mathbb{P}(X_n = j \mid X_0 = i) = (P^n)_{ij}$$

Also: Einfach die Matrix n -mal mit sich selbst multiplizieren!

Beispiel (Wetter)

Wie ist das Wetter übermorgen, wenn heute Sonne?

$$P^2 = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}^2 = \begin{pmatrix} 0.72 & 0.28 \\ 0.56 & 0.44 \end{pmatrix}$$

$\Rightarrow$ Wahrscheinlichkeit für Sonne übermorgen: 0.72.

Rekursive Definition

```
noncomputable def matMul (P Q : S N -> S N -> Real) :=  
  fun x z => Sum y, P x y * Q y z  
  
noncomputable def matPow (P : S N -> S N -> Real) :  
  Nat -> S N -> S N -> Real  
| 0      => fun x z => if x = z then 1 else 0  
| n + 1 => matMul (matPow P n) P
```

Rekursive Definition

```
noncomputable def matMul (P Q : S N -> S N -> Real) :=  
  fun x z => Sum y, P x y * Q y z
```

```
noncomputable def matPow (P : S N -> S N -> Real) :  
  Nat -> S N -> S N -> Real  
| 0      => fun x z => if x = z then 1 else 0  
| n + 1 => matMul (matPow P n) P
```

Korrespondenz

$P^0 = I$ (Einheitsmatrix)	$\longleftrightarrow$	$\text{if } x = z \text{ then } 1 \text{ else } 0$
$P^{n+1} = P^n \cdot P$	$\longleftrightarrow$	$\text{matMul (matPow P n) P}$
$(P^n)_{xz} = \sum_y P_{xy}^n P_{yz}$	$\longleftrightarrow$	$\sum y, P x y * Q y z$

Anfangsverteilung

Die Verteilung von X_0 wird als **Anfangsverteilung** μ_0 bezeichnet:

$$\mu_0(i) = \mathbb{P}(X_0 = i), \quad i \in S$$

Als Zeilenvektor: $\mu_0 = (\mu_0(1), \mu_0(2), \dots)$

Anfangsverteilung

Die Verteilung von X_0 wird als **Anfangsverteilung** μ_0 bezeichnet:

$$\mu_0(i) = \mathbb{P}(X_0 = i), \quad i \in S$$

Als Zeilenvektor: $\mu_0 = (\mu_0(1), \mu_0(2), \dots)$

Verteilung nach n Schritten

$$\mu_n = \mu_0 \cdot P^n$$

Markov-Ketten

Verteilung zum Zeitpunkt n

Anfangsverteilung

Die Verteilung von X_0 wird als **Anfangsverteilung** μ_0 bezeichnet:

$$\mu_0(i) = \mathbb{P}(X_0 = i), \quad i \in S$$

Als Zeilenvektor: $\mu_0 = (\mu_0(1), \mu_0(2), \dots)$

Verteilung nach n Schritten

$$\mu_n = \mu_0 \cdot P^n$$

Beispiel (Wetter)

Start: $\mu_0 = (1, 0)$ (heute sicher Sonne). Nach 2 Tagen:

$$\mu_2 = (1, 0) \cdot P^2 = (0.72, 0.28)$$

Definition (Invariante Verteilung)

Ein Wahrscheinlichkeitsvektor $\pi = (\pi_1, \pi_2, \dots)$ heißt **invariante** (oder **stationäre**) **Verteilung** der Markov-Kette mit Übergangsmatrix P , falls:

$$\pi \cdot P = \pi$$

d.h. π ist ein Linkseigenvektor von P zum Eigenwert 1.

Markov-Ketten

Invariante (stationäre) Verteilung – Definition

Definition (Invariante Verteilung)

Ein Wahrscheinlichkeitsvektor $\pi = (\pi_1, \pi_2, \dots)$ heißt **invariante** (oder **stationäre**) **Verteilung** der Markov-Kette mit Übergangsmatrix P , falls:

$$\pi \cdot P = \pi$$

d.h. π ist ein Linkseigenvektor von P zum Eigenwert 1.

Interpretation

Startet die Kette mit Verteilung π , so bleibt die Verteilung für alle Zeiten π :

$$\mu_0 = \pi \Rightarrow \mu_n = \pi \cdot P^n = \pi \quad \text{für alle } n.$$

Das System befindet sich im “Gleichgewicht”.

Definitionen in Lean

```
def IsDistribution (pi : S N -> Real) : Prop :=  
  (forall i, 0 <= pi i) /\ (Sum i, pi i) = 1
```

```
def IsInvariant (P : S N -> S N -> Real)  
  (pi : S N -> Real) : Prop :=  
  forall j, (Sum i, pi i * P i j) = pi j
```

Definitionen in Lean

```
def IsDistribution (pi : S N -> Real) : Prop :=  
  (forall i, 0 <= pi i) /\ (Sum i, pi i) = 1
```

```
def IsInvariant (P : S N -> S N -> Real)  
  (pi : S N -> Real) : Prop :=  
  forall j, (Sum i, pi i * P i j) = pi j
```

Korrespondenz

$$(\pi P)_j = \sum_i \pi_i \cdot P_{ij} = \pi_j \quad \longleftrightarrow \quad \forall j, \left(\sum_i \pi_i * P_{ij} \right) = \pi_j$$

Man beachte: Die Summe $\sum_i \pi_i P_{ij}$ über die Spalte j entspricht der Linksmultiplikation πP .

Markov-Ketten

Beispiel: Invariante Verteilung berechnen

Wetter-Beispiel

Gesucht: $\pi = (\pi_S, \pi_R)$ mit $\pi P = \pi$ und $\pi_S + \pi_R = 1$.

Markov-Ketten

Beispiel: Invariante Verteilung berechnen

Wetter-Beispiel

Gesucht: $\pi = (\pi_S, \pi_R)$ mit $\pi P = \pi$ und $\pi_S + \pi_R = 1$.

$$\begin{aligned}\pi P = \pi &\Leftrightarrow \begin{cases} 0.8\pi_S + 0.4\pi_R = \pi_S \\ 0.2\pi_S + 0.6\pi_R = \pi_R \end{cases} \\ &\Leftrightarrow \begin{cases} -0.2\pi_S + 0.4\pi_R = 0 \\ 0.2\pi_S - 0.4\pi_R = 0 \end{cases} \\ &\Leftrightarrow \pi_S = 2\pi_R\end{aligned}$$

Markov-Ketten

Beispiel: Invariante Verteilung berechnen

Wetter-Beispiel

Gesucht: $\pi = (\pi_S, \pi_R)$ mit $\pi P = \pi$ und $\pi_S + \pi_R = 1$.

$$\begin{aligned}\pi P = \pi &\Leftrightarrow \begin{cases} 0.8\pi_S + 0.4\pi_R = \pi_S \\ 0.2\pi_S + 0.6\pi_R = \pi_R \end{cases} \\ &\Leftrightarrow \begin{cases} -0.2\pi_S + 0.4\pi_R = 0 \\ 0.2\pi_S - 0.4\pi_R = 0 \end{cases} \\ &\Leftrightarrow \pi_S = 2\pi_R\end{aligned}$$

$$\text{Mit } \pi_S + \pi_R = 1: \quad 2\pi_R + \pi_R = 1 \quad \Rightarrow \quad \pi_R = \frac{1}{3}, \quad \pi_S = \frac{2}{3}.$$

$$\pi = \left(\frac{2}{3}, \frac{1}{3} \right)$$

Interpretation: Langfristig ist es $2/3$ der Zeit sonnig und $1/3$ der Zeit regnerisch.

Definition und Beweis in Lean

```
def weatherPi : S 2 -> Real
| <0, _> => 2/3
| <1, _> => 1/3

lemma weatherPi_isInvariant :
  IsInvariant weatherP weatherPi := by
  intro j
  fin_cases j <;>
  simp [weatherP, weatherPi, Fin.sum_univ_two]
  <;> ring
```

Definition und Beweis in Lean

```
def weatherPi : S 2 -> Real
| <0, _> => 2/3
| <1, _> => 1/3

lemma weatherPi_isInvariant :
  IsInvariant weatherP weatherPi := by
  intro j
  fin_cases j <;>
  simp [weatherP, weatherPi, Fin.sum_univ_two]
  <;> ring
```

Was passiert hier?

- `fin_cases j`: Fallunterscheidung über $j \in \{0, 1\}$.
- `simp`: Vereinfacht die Summe $\sum_i \pi_i P_{ij}$.
- `ring`: Verifiziert die arithmetische Gleichung.

Definition (Irreduzibel)

Eine Markov-Kette heißt **irreduzibel**, falls man von jedem Zustand i jeden anderen Zustand j mit positiver Wahrscheinlichkeit in endlich vielen Schritten erreichen kann:

$$\forall i, j \in S \exists n \geq 1 : p_{ij}^{(n)} > 0$$

Definition (Irreduzibel)


Eine Markov-Kette heißt **irreduzibel**, falls man von jedem Zustand i jeden anderen Zustand j mit positiver Wahrscheinlichkeit in endlich vielen Schritten erreichen kann:

$$\forall i, j \in S \exists n \geq 1 : p_{ij}^{(n)} > 0$$

Irreduzibel:



Nicht irreduzibel:



Interpretation: Alle Zustände “kommunizieren” miteinander.

Definition in Lean

```
def IsIrreducible (P : S N -> S N -> Real) : Prop :=  
  forall i j, exists n, 0 < n /\ 0 < matPow P n i j
```

Definition in Lean

```
def IsIrreducible (P : S N -> S N -> Real) : Prop :=  
  forall i j, exists n, 0 < n /\ 0 < matPow P n i j
```

Beweis: Wetter-Kette ist irreduzibel

```
lemma weatherP_irreducible :  
  IsIrreducible weatherP := by  
  intro i j  
  exact <1, Nat.one_pos, by  
    fin_cases i <;> fin_cases j <;>  
    simp [matPow, matMul, weatherP,  
      Fin.sum_univ_two] <;> norm_num>
```

Alle Einträge von P^1 sind positiv $\Rightarrow$ jeder Zustand ist in einem Schritt erreichbar.

Definition (Periode)

Die **Periode** eines Zustands i ist:

$$d(i) = \gcd\{n \geq 1 : p_{ii}^{(n)} > 0\}$$

Die Kette heißt **aperiodisch**, falls $d(i) = 1$ für alle $i \in S$.

Definition (Periode)

Die **Periode** eines Zustands i ist:


$$d(i) = \gcd\{n \geq 1 : p_{ii}^{(n)} > 0\}$$

Die Kette heißt **aperiodisch**, falls $d(i) = 1$ für alle $i \in S$.

Aperiodisch ($d = 1$):



Periodisch ($d = 2$):



Hinweis: Eine Selbstschleife ($p_{ii} > 0$) garantiert stets $d(i) = 1$.

Beispiel mit 2 Zuständen

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Die Kette springt *immer* zwischen den Zuständen hin und her:

$$1 \rightarrow 2 \rightarrow 1 \rightarrow 2 \rightarrow \dots$$

Beispiel mit 2 Zuständen

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Die Kette springt *immer* zwischen den Zuständen hin und her:

$$1 \rightarrow 2 \rightarrow 1 \rightarrow 2 \rightarrow \dots$$

- Rückkehr zu Zustand 1 nur nach 2, 4, 6, ... Schritten.
- $d(1) = \gcd\{2, 4, 6, \dots\} = 2$. $\Rightarrow$ Periodisch!
- Die invariante Verteilung ist $\pi = (1/2, 1/2)$, aber P^n konvergiert **nicht**!

Periodische Kette in Lean

```
def periodicP : S 2 -> S 2 -> Real
| <0, _>, <0, _> => 0   | <0, _>, <1, _> => 1
| <1, _>, <0, _> => 1   | <1, _>, <1, _> => 0
```

```
def periodicPi : S 2 -> Real
| <0, _> => 1/2
| <1, _> => 1/2
```

```
lemma periodicPi_isInvariant :
  IsInvariant periodicP periodicPi := by
  intro j
  fin_cases j <;>
  simp [periodicP, periodicPi,
    Fin.sum_univ_two] <;> ring
```

$\pi = (1/2, 1/2)$ ist invariant, aber P^n oszilliert!

Satz (Existenz und Eindeutigkeit)

Sei (X_n) eine **irreduzible** Markov-Kette mit endlichem Zustandsraum S . Dann gilt:

- 1 Es existiert **genau eine** invariante Verteilung π .
- 2 $\pi_i > 0$ für alle $i \in S$.
- 3 Ist die Kette zusätzlich **aperiodisch**, so gilt für jede Anfangsverteilung μ_0 :

$$\lim_{n \rightarrow \infty} \mu_0 P^n = \pi$$

d.h. die Verteilung konvergiert gegen π , unabhängig vom Startzustand.

Formales Statement in Lean

```
theorem stationary_unique
  (P : S N -> S N -> Real)
  (hP : IsTransitionMatrix P)
  (hirr : IsIrreducible P)
  (pi1 pi2 : S N -> Real)
  (hpi1_dist : IsDistribution pi1)
  (hpi2_dist : IsDistribution pi2)
  (hpi1_inv : IsInvariant P pi1)
  (hpi2_inv : IsInvariant P pi2) :
  pi1 = pi2
```

Markov-Ketten

Lean – Hauptsatz (Statement)

Formales Statement in Lean

```
theorem stationary_unique
  (P : S N -> S N -> Real)
  (hP : IsTransitionMatrix P)
  (hirr : IsIrreducible P)
  (pi1 pi2 : S N -> Real)
  (hpi1_dist : IsDistribution pi1)
  (hpi2_dist : IsDistribution pi2)
  (hpi1_inv : IsInvariant P pi1)
  (hpi2_inv : IsInvariant P pi2) :
  pi1 = pi2
```

Beweis-Strategie

Definiere $f = \pi_1 - \pi_2$. Dann ist f harmonisch ($Pf = f$) und $\sum f_i = 0$. Das Maximumsprinzip + Irreduzibilität erzwingt $f = 0$.

Existenz einer invarianten Verteilung

Betrachte die Cesàro-Mittel der Übergangsmatrizen:

$$\overline{P}_n := \frac{1}{n} \sum_{k=0}^{n-1} P^k$$

Existenz einer invarianten Verteilung

Betrachte die Cesàro-Mittel der Übergangsmatrizen:

$$\overline{P}_n := \frac{1}{n} \sum_{k=0}^{n-1} P^k$$

- Da S endlich ist, liegt jede Zeile von $\overline{P}_n$ in einem kompakten Raum (Simplex der Wahrscheinlichkeitsvektoren).

Existenz einer invarianten Verteilung

Betrachte die Cesàro-Mittel der Übergangsmatrizen:

$$\overline{P}_n := \frac{1}{n} \sum_{k=0}^{n-1} P^k$$

- Da S endlich ist, liegt jede Zeile von $\overline{P}_n$ in einem kompakten Raum (Simplex der Wahrscheinlichkeitsvektoren).
- Nach dem Satz von Bolzano-Weierstraß existiert eine konvergente Teilfolge $\overline{P}_{n_k} \rightarrow Q$.

Existenz einer invarianten Verteilung

Betrachte die Cesàro-Mittel der Übergangsmatrizen:

$$\overline{P}_n := \frac{1}{n} \sum_{k=0}^{n-1} P^k$$

- Da S endlich ist, liegt jede Zeile von $\overline{P}_n$ in einem kompakten Raum (Simplex der Wahrscheinlichkeitsvektoren).
- Nach dem Satz von Bolzano-Weierstraß existiert eine konvergente Teilfolge $\overline{P}_{n_k} \rightarrow Q$.
- Jede Zeile q_i von Q ist ein Wahrscheinlichkeitsvektor mit $q_i \cdot P = q_i$:

$$\overline{P}_n \cdot P = \frac{1}{n} \sum_{k=0}^{n-1} P^{k+1} = \overline{P}_n + \frac{1}{n}(P^n - I) \rightarrow Q$$

Also $Q \cdot P = Q$, d.h. jede Zeile von Q ist invariant.

Alle Einträge von π sind positiv

Sei π eine invariante Verteilung und $i \in S$ beliebig.

Alle Einträge von π sind positiv

Sei π eine invariante Verteilung und $i \in S$ beliebig.

- Da die Kette irreduzibel ist, gibt es für jedes j mit $\pi_j > 0$ ein $m \geq 1$ mit $p_{ji}^{(m)} > 0$.

Alle Einträge von π sind positiv

Sei π eine invariante Verteilung und $i \in S$ beliebig.

- Da die Kette irreduzibel ist, gibt es für jedes j mit $\pi_j > 0$ ein $m \geq 1$ mit $p_{ji}^{(m)} > 0$.
- Aus $\pi = \pi P^m$ folgt:

$$\pi_i = \sum_{k \in S} \pi_k \cdot p_{ki}^{(m)} \geq \pi_j \cdot p_{ji}^{(m)} > 0$$

Alle Einträge von π sind positiv

Sei π eine invariante Verteilung und $i \in S$ beliebig.

- Da die Kette irreduzibel ist, gibt es für jedes j mit $\pi_j > 0$ ein $m \geq 1$ mit $p_{ji}^{(m)} > 0$.
- Aus $\pi = \pi P^m$ folgt:

$$\pi_i = \sum_{k \in S} \pi_k \cdot p_{ki}^{(m)} \geq \pi_j \cdot p_{ji}^{(m)} > 0$$

- Da mindestens ein $\pi_j > 0$ existieren muss (π ist Wahrscheinlichkeitsvektor), folgt $\pi_i > 0$ für alle i .

Schlüssel-Lemma: $\pi = \pi P^n$

```
lemma invariant_of_pow (P : S N -> S N -> Real)
  (pi : S N -> Real) (hInv : IsInvariant P pi) :
  forall n, forall j, (Sum i, pi i * matPow P n i j) = pi j
```

Schlüssel-Lemma: $\pi = \pi P^n$

```
lemma invariant_of_pow (P : S N -> S N -> Real)
  (pi : S N -> Real) (hInv : IsInvariant P pi) :
  forall n, forall j, (Sum i, pi i * matPow P n i j) = pi j
```

Positivität

```
theorem stationary_pos (P : S N -> S N -> Real)
  (hP : IsTransitionMatrix P)
  (hirr : IsIrreducible P) (pi : S N -> Real)
  (hpi_dist : IsDistribution pi)
  (hpi_inv : IsInvariant P pi) :
  forall i, 0 < pi i
```

Beweis: $\exists j$ mit $\pi_j > 0$. Irreduzibilität liefert n mit $P_{ji}^n > 0$.

Dann $\pi_i = \sum_k \pi_k P_{ki}^n \geq \pi_j P_{ji}^n > 0$.

Die invariante Verteilung ist eindeutig

Angenommen, π und $\tilde{\pi}$ sind zwei invariante Verteilungen.

Die invariante Verteilung ist eindeutig

Angenommen, π und $\tilde{\pi}$ sind zwei invariante Verteilungen.

Definiere $f := \pi - \tilde{\pi}$. Dann gilt:

- $f \cdot P = f$ (Differenz zweier Fixpunkte ist Fixpunkt)
- $\sum_i f_i = 1 - 1 = 0$

Die invariante Verteilung ist eindeutig

Angenommen, π und $\tilde{\pi}$ sind zwei invariante Verteilungen.

Definiere $f := \pi - \tilde{\pi}$. Dann gilt:

- $f \cdot P = f$ (Differenz zweier Fixpunkte ist Fixpunkt)
- $\sum_j f_j = 1 - 1 = 0$

Sei $i^* = \arg \max_j f_j$. Aus $f = fP$ folgt:

$$f_{i^*} = \sum_j p_{i^*j} f_j \leq f_{i^*} \cdot \underbrace{\sum_j p_{i^*j}}_{=1} = f_{i^*}$$

Gleichheit gilt nur, wenn $f_j = f_{i^*}$ für alle j mit $p_{i^*j} > 0$.

Schluss per Irreduzibilität

Wir haben gezeigt: $f_j = f_{i^*}$ für alle j mit $p_{i^*j} > 0$.

Schluss per Irreduzibilität

Wir haben gezeigt: $f_j = f_{i^*}$ für alle j mit $p_{i^*j} > 0$.

- Wiederhole das Argument: Wenn $f_j = f_{i^*}$ und $p_{jk} > 0$, dann auch $f_k = f_{i^*}$.

Schluss per Irreduzibilität

Wir haben gezeigt: $f_j = f_{i^*}$ für alle j mit $p_{i^*j} > 0$.

- Wiederhole das Argument: Wenn $f_j = f_{i^*}$ und $p_{jk} > 0$, dann auch $f_k = f_{i^*}$.
- Da die Kette **irreduzibel** ist, kann man von i^* jeden Zustand $k \in S$ in endlich vielen Schritten erreichen.

Schluss per Irreduzibilität

Wir haben gezeigt: $f_j = f_{i^*}$ für alle j mit $p_{i^*j} > 0$.

- Wiederhole das Argument: Wenn $f_j = f_{i^*}$ und $p_{jk} > 0$, dann auch $f_k = f_{i^*}$.
- Da die Kette **irreduzibel** ist, kann man von i^* jeden Zustand $k \in S$ in endlich vielen Schritten erreichen.
- Also: $f_k = f_{i^*}$ für **alle** $k \in S$.

Schluss per Irreduzibilität

Wir haben gezeigt: $f_j = f_{i^*}$ für alle j mit $p_{i^*j} > 0$.

- Wiederhole das Argument: Wenn $f_j = f_{i^*}$ und $p_{jk} > 0$, dann auch $f_k = f_{i^*}$.
- Da die Kette **irreduzibel** ist, kann man von i^* jeden Zustand $k \in S$ in endlich vielen Schritten erreichen.
- Also: $f_k = f_{i^*}$ für **alle** $k \in S$.
- Da $\sum_k f_k = 0$ und alle f_k gleich sind: $|S| \cdot f_{i^*} = 0$, also $f_{i^*} = 0$.

Schluss per Irreduzibilität

Wir haben gezeigt: $f_j = f_{i^*}$ für alle j mit $p_{i^*j} > 0$.

- Wiederhole das Argument: Wenn $f_j = f_{i^*}$ und $p_{jk} > 0$, dann auch $f_k = f_{i^*}$.
- Da die Kette **irreduzibel** ist, kann man von i^* jeden Zustand $k \in S$ in endlich vielen Schritten erreichen.
- Also: $f_k = f_{i^*}$ für **alle** $k \in S$.
- Da $\sum_k f_k = 0$ und alle f_k gleich sind: $|S| \cdot f_{i^*} = 0$, also $f_{i^*} = 0$.
- Damit $f = 0$, d.h. $\pi = \tilde{\pi}$. □

Harmonische Funktionen

```
def IsHarmonic (P : S N -> S N -> Real) (f : S N -> Real) :=  
  forall x, stepOp P f x = f x
```

```
theorem harmonic_const_of_irreducible  
  (P : S N -> S N -> Real) (hP : IsTransitionMatrix P)  
  (hirr : IsIrreducible P)  
  (f : S N -> Real) (hf : IsHarmonic P f) :  
  forall i j, f i = f j
```

Harmonische Funktionen

```
def IsHarmonic (P : S N -> S N -> Real) (f : S N -> Real) :=  
  forall x, stepOp P f x = f x
```

```
theorem harmonic_const_of_irreducible  
  (P : S N -> S N -> Real) (hP : IsTransitionMatrix P)  
  (hirr : IsIrreducible P)  
  (f : S N -> Real) (hf : IsHarmonic P f) :  
  forall i j, f i = f j
```

Beweisstruktur

f harmonisch $\Rightarrow f(i^*) = \sum_j P_{i^*j} f(j)$, wobei $f(i^*) = \max f$.
Da $f(i^*) \geq f(j)$ und Konvexkombination: $f(j) = f(i^*)$ für $P_{i^*j} > 0$.
Irreduzibilität propagiert dies auf alle $j \in S$.

Bei Aperiodizität: $P^n \rightarrow \Pi$ (alle Zeilen = π)

Bei Aperiodizität: $P^n \rightarrow \Pi$ (alle Zeilen = π)

- Definiere den **Variationsabstand**: $\|u - v\|_{TV} = \frac{1}{2} \sum_i |u_i - v_i|$.

Bei Aperiodizität: $P^n \rightarrow \Pi$ (alle Zeilen = π)

- Definiere den **Variationsabstand**: $\|u - v\|_{TV} = \frac{1}{2} \sum_i |u_i - v_i|$.
- Für jede Zeile $e_i P^n$ (Verteilung nach n Schritten, Start in i):

$$\|e_i P^n - \pi\|_{TV} = \|e_i P^n - \pi P^n\|_{TV} \leq \|e_i - \pi\|_{TV} \cdot \rho^n$$

wobei $\rho < 1$ (Kontraktionseigenschaft bei Irreduzibilität + Aperiodizität).

Bei Aperiodizität: $P^n \rightarrow \Pi$ (alle Zeilen = π)

- Definiere den **Variationsabstand**: $\|u - v\|_{TV} = \frac{1}{2} \sum_i |u_i - v_i|$.
- Für jede Zeile $e_i P^n$ (Verteilung nach n Schritten, Start in i):

$$\|e_i P^n - \pi\|_{TV} = \|e_i P^n - \pi P^n\|_{TV} \leq \|e_i - \pi\|_{TV} \cdot \rho^n$$

wobei $\rho < 1$ (Kontraktionseigenschaft bei Irreduzibilität + Aperiodizität).

- Da $\rho^n \rightarrow 0$: Konvergenz gegen π für jede Anfangsverteilung.
 $\square$

Wetter-Beispiel: Potenzen von P

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}, \quad P^5 \approx \begin{pmatrix} 0.672 & 0.328 \\ 0.656 & 0.344 \end{pmatrix}, \quad P^{20} \approx \begin{pmatrix} 0.667 & 0.333 \\ 0.667 & 0.333 \end{pmatrix}$$

Wetter-Beispiel: Potenzen von P

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}, \quad P^5 \approx \begin{pmatrix} 0.672 & 0.328 \\ 0.656 & 0.344 \end{pmatrix}, \quad P^{20} \approx \begin{pmatrix} 0.667 & 0.333 \\ 0.667 & 0.333 \end{pmatrix}$$

- Die Zeilen von P^n konvergieren beide gegen $\pi = (2/3, 1/3)$.
- Egal ob Start in Sonne oder Regen – langfristig gleiche Verteilung!

Wetter-Beispiel: Potenzen von P

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}, \quad P^5 \approx \begin{pmatrix} 0.672 & 0.328 \\ 0.656 & 0.344 \end{pmatrix}, \quad P^{20} \approx \begin{pmatrix} 0.667 & 0.333 \\ 0.667 & 0.333 \end{pmatrix}$$

- Die Zeilen von P^n konvergieren beide gegen $\pi = (2/3, 1/3)$.
- Egal ob Start in Sonne oder Regen – langfristig gleiche Verteilung!

Numerische Verifikation

$$\begin{aligned} \pi P &= (2/3, 1/3) \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix} = \\ & (2/3 \cdot 0.8 + 1/3 \cdot 0.4, 2/3 \cdot 0.2 + 1/3 \cdot 0.6) = (2/3, 1/3) \checkmark \end{aligned}$$

Markov-Ketten

Beispiel: Invariante Verteilung (3 Zustände)

Stimmungs-Modell

$$P = \begin{pmatrix} 0.5 & 0.4 & 0.1 \\ 0.3 & 0.4 & 0.3 \\ 0.2 & 0.3 & 0.5 \end{pmatrix}$$

Gesucht: $\pi = (\pi_G, \pi_N, \pi_S)$ mit $\pi P = \pi$, $\pi_G + \pi_N + \pi_S = 1$.

Markov-Ketten

Beispiel: Invariante Verteilung (3 Zustände)

Stimmungs-Modell

$$P = \begin{pmatrix} 0.5 & 0.4 & 0.1 \\ 0.3 & 0.4 & 0.3 \\ 0.2 & 0.3 & 0.5 \end{pmatrix}$$

Gesucht: $\pi = (\pi_G, \pi_N, \pi_S)$ mit $\pi P = \pi$, $\pi_G + \pi_N + \pi_S = 1$.

Gleichungssystem:

$$0.5\pi_G + 0.3\pi_N + 0.2\pi_S = \pi_G$$

$$0.4\pi_G + 0.4\pi_N + 0.3\pi_S = \pi_N$$

$$\pi_G + \pi_N + \pi_S = 1$$

Markov-Ketten

Beispiel: Invariante Verteilung (3 Zustände)

Stimmungs-Modell

$$P = \begin{pmatrix} 0.5 & 0.4 & 0.1 \\ 0.3 & 0.4 & 0.3 \\ 0.2 & 0.3 & 0.5 \end{pmatrix}$$

Gesucht: $\pi = (\pi_G, \pi_N, \pi_S)$ mit $\pi P = \pi$, $\pi_G + \pi_N + \pi_S = 1$.

Gleichungssystem:

$$0.5\pi_G + 0.3\pi_N + 0.2\pi_S = \pi_G$$

$$0.4\pi_G + 0.4\pi_N + 0.3\pi_S = \pi_N$$

$$\pi_G + \pi_N + \pi_S = 1$$

Lösung: $\pi = \left(\frac{1}{3}, \frac{11}{30}, \frac{3}{10}\right) \approx (0.333, 0.367, 0.300)$

Definition (Detailed Balance)

Eine Verteilung π erfüllt die **Detailed-Balance-Bedingung** bzgl. P , falls:

$$\pi_i \cdot p_{ij} = \pi_j \cdot p_{ji} \quad \text{für alle } i, j \in S$$

Definition (Detailed Balance)

Eine Verteilung π erfüllt die **Detailed-Balance-Bedingung** bzgl. P , falls:

$$\pi_i \cdot p_{ij} = \pi_j \cdot p_{ji} \quad \text{für alle } i, j \in S$$

Satz

Erfüllt π die Detailed-Balance-Bedingung, so ist π invariant.

Definition (Detailed Balance)

Eine Verteilung π erfüllt die **Detailed-Balance-Bedingung** bzgl. P , falls:

$$\pi_i \cdot p_{ij} = \pi_j \cdot p_{ji} \quad \text{für alle } i, j \in S$$

Satz

Erfüllt π die Detailed-Balance-Bedingung, so ist π invariant.

Beweis

$$(\pi P)_j = \sum_i \pi_i p_{ij} = \sum_i \pi_j p_{ji} = \pi_j \underbrace{\sum_i p_{ji}}_{=1} = \pi_j \quad \checkmark$$

Interpretation: Im Gleichgewicht ist der “Fluss” von i nach j gleich dem Fluss von j nach i .

Definition und Satz in Lean

```
def DetailedBalance (P : S N -> S N -> Real)
  (pi : S N -> Real) : Prop :=
  forall i j, pi i * P i j = pi j * P j i

theorem detailedBalance_implies_invariant
  (hP : IsTransitionMatrix P)
  (hdb : DetailedBalance P pi) :
  IsInvariant P pi := by
  intro j
  calc Sum i, pi i * P i j
    = Sum i, pi j * P j i := by
      congr 1; ext i; exact hdb i j
  _ = pi j * Sum i, P j i := by
      rw [Finset.mul_sum]
  _ = pi j := by rw [hP.2 j, mul_one]
```

Wetter-Beispiel: Prüfe Detailed Balance

$$\pi = (2/3, 1/3), \quad P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$$

Wetter-Beispiel: Prüfe Detailed Balance

$$\pi = (2/3, 1/3), \quad P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$$

Prüfe $\pi_S \cdot p_{SR} = \pi_R \cdot p_{RS}$:

$$\frac{2}{3} \cdot 0.2 = \frac{2}{15} \quad \text{und} \quad \frac{1}{3} \cdot 0.4 = \frac{2}{15} \quad \checkmark$$

Wetter-Beispiel: Prüfe Detailed Balance

$$\pi = (2/3, 1/3), \quad P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$$

Prüfe $\pi_S \cdot p_{SR} = \pi_R \cdot p_{RS}$:

$$\frac{2}{3} \cdot 0.2 = \frac{2}{15} \quad \text{und} \quad \frac{1}{3} \cdot 0.4 = \frac{2}{15} \quad \checkmark$$

$\Rightarrow$ Das Wetter-Modell ist **reversibel**.

Nicht jede Kette ist reversibel! Beispiel: Kreislauf

$1 \rightarrow 2 \rightarrow 3 \rightarrow 1$ mit

$$P = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}$$

hat $\pi = (1/3, 1/3, 1/3)$, aber $\pi_1 p_{12} = 1/3 \neq 0 = \pi_2 p_{21}$.

Zentrale Begriffe

- **Markov-Kette:** Zukunft hängt nur von Gegenwart ab.
- **Stochastische Matrix:** Zeilensummen = 1, Einträge ≥ 0 .
- **Invariante Verteilung:** $\pi P = \pi$ (Gleichgewicht).
- **Irreduzibel:** Jeder Zustand von jedem erreichbar.
- **Aperiodisch:** Keine periodischen Zyklen.

Zentrale Begriffe

- **Markov-Kette:** Zukunft hängt nur von Gegenwart ab.
- **Stochastische Matrix:** Zeilensummen = 1, Einträge ≥ 0 .
- **Invariante Verteilung:** $\pi P = \pi$ (Gleichgewicht).
- **Irreduzibel:** Jeder Zustand von jedem erreichbar.
- **Aperiodisch:** Keine periodischen Zyklen.

Hauptsatz

Irreduzibel + endlich $\Rightarrow$ es existiert genau eine invariante Verteilung $\pi > 0$.

+ **Aperiodisch** $\Rightarrow$ Konvergenz: $P^n \rightarrow$ Matrix mit Zeilen π .

Alle Definitionen und Beweise sind in Lean 4 / Mathlib formalisierbar!

Siehe: `code/LeanMath/stochastic/markov_invariant.lean`