

Wahrscheinlichkeitstheorie und Statistik (Stochastik) Markov-Ketten

Dr. rer. nat. Johannes Riesterer

Idee

Viele Prozesse in der Informatik und im Alltag können als Folge von Zuständen modelliert werden, bei denen der nächste Zustand nur vom aktuellen Zustand abhängt – nicht von der gesamten Vergangenheit.

Beispiele

- Websurfen: Die nächste Seite hängt nur von der aktuellen ab (PageRank).
- Wetter: Morgen Regen/Sonne hängt nur vom heutigen Wetter ab.
- Kartenmischen: Die nächste Anordnung hängt nur von der aktuellen ab.
- Warteschlangen: Anzahl Kunden hängt nur vom aktuellen Zustand ab.

Definition (Stochastische Matrix)

Eine Matrix $P = (p_{ij})_{i,j \in S}$ mit Zustandsraum S heißt **stochastische Matrix**, falls:

- 1 $p_{ij} \geq 0$ für alle $i, j \in S$
- 2 $\sum_{j \in S} p_{ij} = 1$ für alle $i \in S$ (Zeilensumme = 1)

Interpretation


p_{ij} ist die Wahrscheinlichkeit, vom Zustand i in den Zustand j zu wechseln.

Markov-Ketten

Beispiel: Wetter mit 2 Zuständen

Zustandsraum

$$S = \{S(\text{onne}), R(\text{egen})\}$$



Übergangsmatrix

$$P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$$

Zeile 1: Wenn heute Sonne, dann morgen Sonne mit 0.8, Regen mit 0.2.

Definition (Markov-Kette)

Eine Folge $(X_n)_{n \in \mathbb{N}_0}$ von Zufallsvariablen mit Werten in S heißt **Markov-Kette** mit Übergangsmatrix P , falls:

$$\mathbb{P}(X_{n+1} = j \mid X_n = i, X_{n-1}, \dots, X_0) = \mathbb{P}(X_{n+1} = j \mid X_n = i) = p_{ij}$$

für alle $n \in \mathbb{N}_0$ und alle $i, j \in S$.

Markov-Eigenschaft (Gedächtnislosigkeit)


Die Zukunft hängt nur von der Gegenwart ab, nicht von der Vergangenheit!

Markov-Ketten

Beispiel: 3 Zustände (Stimmung)

Modell

$S = \{G(\text{ut}), N(\text{eutral}), S(\text{chlecht})\}$



$$P = \begin{pmatrix} 0.5 & 0.4 & 0.1 \\ 0.3 & 0.4 & 0.3 \\ 0.2 & 0.3 & 0.5 \end{pmatrix}$$

Satz (Chapman-Kolmogorov)

Die Wahrscheinlichkeit, in n Schritten von i nach j zu gelangen:

$$p_{ij}^{(n)} = \mathbb{P}(X_n = j \mid X_0 = i) = (P^n)_{ij}$$

Also: Einfach die Matrix n -mal mit sich selbst multiplizieren!

Beispiel (Wetter)

Wie ist das Wetter übermorgen, wenn heute Sonne?

$$P^2 = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}^2 = \begin{pmatrix} 0.72 & 0.28 \\ 0.56 & 0.44 \end{pmatrix}$$

$\Rightarrow$ Wahrscheinlichkeit für Sonne übermorgen: 0.72.

Beweis ($P^{m+n} = P^m \cdot P^n$)

$$p_{ij}^{(m+n)} = \mathbb{P}(X_{m+n} = j \mid X_0 = i) \quad (\text{Definition})$$

$$= \sum_{k \in S} \mathbb{P}(X_{m+n} = j, X_m = k \mid X_0 = i) \quad (\text{Tot. W'keit})$$

$$= \sum_{k \in S} \mathbb{P}(X_{m+n} = j \mid X_m = k, X_0 = i) \cdot p_{ik}^{(m)} \quad (\text{Def. bed. W'keit})$$

$$= \sum_{k \in S} \mathbb{P}(X_{m+n} = j \mid X_m = k) \cdot p_{ik}^{(m)} \quad (\text{Markov-Eig.})$$

$$= \sum_{k \in S} p_{ik}^{(m)} \cdot p_{kj}^{(n)} \quad (\text{Homogenität}) \quad \square$$

Markov-Ketten

Bemerkung: $P^{(m)} = P^m$

Was haben wir gerade gezeigt?

Mit $P^{(m)} := (p_{ij}^{(m)})_{i,j \in S}$ liefert die Rechnung komponentenweise

$$P^{(m+n)} = P^{(m)} \cdot P^{(n)} \quad (\star)$$

– eine Aussage über die $P^{(\cdot)}$, noch nicht über Matrixpotenzen P^m !

Induktion: $P^{(m)} = P^m$

Basis ($m = 1$): $P_{ij}^{(1)} = p_{ij}$, also $P^{(1)} = P$.

Schritt: Mit $n = 1$ in $(\star)$ folgt

$$P^{(m+1)} = P^{(m)} \cdot P \stackrel{\text{IV}}{=} P^m \cdot P = P^{m+1}.$$

Folgerung

$$P^{m+n} = P^{(m+n)} \stackrel{(\star)}{=} P^{(m)} \cdot P^{(n)} = P^m \cdot P^n. \quad \square$$

Definition

Für einen **Zeilenvektor** $\mu = (\mu_1, \dots, \mu_N) \in \mathbb{R}^{1 \times N}$ und $P = (p_{ij}) \in \mathbb{R}^{N \times N}$ ist $\mu \cdot P \in \mathbb{R}^{1 \times N}$ definiert durch

$$(\mu \cdot P)_j = \sum_{i=1}^N \mu_i p_{ij}, \quad j = 1, \dots, N.$$

Das ist das gewöhnliche Matrixprodukt einer $1 \times N$ - mit einer $N \times N$ -Matrix.

Wahrscheinlichkeitsinterpretation (totale W'keit)

Mit $\mu_i = \mathbb{P}(X_n = i)$ und $p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i)$:

$$(\mu P)_j = \sum_i \mathbb{P}(X_n = i) \mathbb{P}(X_{n+1} = j \mid X_n = i) = \mathbb{P}(X_{n+1} = j).$$

Markov-Ketten

Verteilung zum Zeitpunkt n

Anfangsverteilung

Die Verteilung von X_0 wird als **Anfangsverteilung** μ_0 bezeichnet:

$$\mu_0(i) = \mathbb{P}(X_0 = i), \quad i \in S$$

Als Zeilenvektor: $\mu_0 = (\mu_0(1), \mu_0(2), \dots)$

Verteilung nach n Schritten

$$\mu_n = \mu_0 \cdot P^n$$

Beispiel (Wetter)

Start: $\mu_0 = (1, 0)$ (heute sicher Sonne). Nach 2 Tagen:

$$\mu_2 = (1, 0) \cdot P^2 = (0.72, 0.28)$$

Definition (Invariante Verteilung)

Ein Wahrscheinlichkeitsvektor $\pi = (\pi_1, \pi_2, \dots)$ heißt **invariante** (oder **stationäre**) **Verteilung**, falls:

$$\pi \cdot P = \pi$$

d.h. π ist ein Linkseigenvektor von P zum Eigenwert 1.

Interpretation

Startet die Kette mit Verteilung π , bleibt sie für alle Zeiten bei π :

$$\mu_0 = \pi \Rightarrow \mu_n = \pi \cdot P^n = \pi \quad \text{für alle } n.$$

Das System befindet sich im Gleichgewicht.

Markov-Ketten

Beispiel: Invariante Verteilung berechnen

Wetter-Beispiel

Gesucht: $\pi = (\pi_S, \pi_R)$ mit $\pi P = \pi$ und $\pi_S + \pi_R = 1$.

$$\begin{aligned}\pi P = \pi &\Leftrightarrow \begin{cases} 0.8\pi_S + 0.4\pi_R = \pi_S \\ 0.2\pi_S + 0.6\pi_R = \pi_R \end{cases} \\ &\Leftrightarrow -0.2\pi_S + 0.4\pi_R = 0 \\ &\Leftrightarrow \pi_S = 2\pi_R\end{aligned}$$

Mit $\pi_S + \pi_R = 1$: $2\pi_R + \pi_R = 1 \Rightarrow \pi_R = \frac{1}{3}, \pi_S = \frac{2}{3}.$

$$\pi = \left(\frac{2}{3}, \frac{1}{3} \right)$$

Interpretation: Langfristig ist es $2/3$ der Zeit sonnig und $1/3$ regnerisch.

Definition (Irreduzibel)


Eine Markov-Kette heißt **irreduzibel**, falls man von jedem Zustand i jeden anderen Zustand j erreichen kann:

$$\forall i, j \in S \exists n \geq 1 : p_{ij}^{(n)} > 0$$

Irreduzibel:



Nicht irreduzibel:



Interpretation: Alle Zustände “kommunizieren” miteinander.

Definition (Periode)

Die **Periode** eines Zustands i ist:

$$d(i) = \text{ggT}\{n \geq 1 : p_{ii}^{(n)} > 0\}$$

Die Kette heißt **aperiodisch**, falls $d(i) = 1$ für alle $i \in S$.

Aperiodisch ($d = 1$):




Periodisch ($d = 2$):



Hinweis: Eine Selbstschleife ($p_{ii} > 0$) garantiert $d(i) = 1$, ist aber nicht notwendig.

Gegenbeispiel

Auch ohne reflexive Kante kann eine Kette aperiodisch sein.



- Rückkehr nach 1 in 2 Schritten: $1 \rightarrow 2 \rightarrow 1$
- Rückkehr nach 1 in 3 Schritten: $1 \rightarrow 3 \rightarrow 2 \rightarrow 1$
- Also: $d(1) = \text{ggT}\{2, 3, \dots\} = 1 \Rightarrow \text{aperiodisch}$

Beispiel mit 2 Zuständen

$$P = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

Die Kette springt *immer* zwischen den Zuständen hin und her:

$$1 \rightarrow 2 \rightarrow 1 \rightarrow 2 \rightarrow \dots$$

- Rückkehr zu Zustand 1 nur nach 2, 4, 6, ... Schritten.
- $d(1) = \text{ggT}\{2, 4, 6, \dots\} = 2. \Rightarrow \text{Periodisch!}$
- Invariante Verteilung: $\pi = (1/2, 1/2)$, aber P^n konvergiert **nicht**:

$$P^{2k} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad P^{2k+1} = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

(oszilliert zwischen zwei Werten).

Satz (Existenz und Eindeutigkeit)

Sei (X_n) eine **irreduzible** Markov-Kette mit endlichem Zustandsraum S . Dann:

- 1 Es existiert **genau eine** invariante Verteilung π .
- 2 $\pi_i > 0$ für alle $i \in S$.
- 3 Ist die Kette zusätzlich **aperiodisch**, so gilt:

$$\lim_{n \rightarrow \infty} \mu_0 P^n = \pi$$

d.h. Konvergenz gegen π , unabhängig vom Startzustand.

Cesàro-Mittel

$\bar{P}_n := \frac{1}{n} \sum_{k=0}^{n-1} P^k$ (Konvexkombination stochastischer Matrizen
 $\Rightarrow$ stochastisch)

- Jede Zeile von $\bar{P}_n$ liegt im **Simplex**
 $\Delta = \{x \in \mathbb{R}^{|S|} : x_i \geq 0, \sum x_i = 1\} \subset [0, 1]^{|S|}.$
- $|S| < \infty \Rightarrow \Delta$ beschränkt + abgeschlossen $\Rightarrow$ **kompakt**
(Heine-Borel).
- **Bolzano-Weierstraß**: $\exists$ konvergente Teilfolge $\bar{P}_{n_k} \rightarrow Q.$
- Jede Zeile q_i von Q ist invariant, denn:

$$\bar{P}_{n_k} \cdot P = \bar{P}_{n_k} + \frac{1}{n_k}(P^{n_k} - I) \xrightarrow{k \rightarrow \infty} Q + 0 = Q$$

Also $Q \cdot P = Q$, d.h. $q_i \cdot P = q_i.$



Alle Einträge von π sind positiv

Sei π eine invariante Verteilung und $i \in S$ beliebig.

- Da die Kette irreduzibel ist, gibt es j mit $\pi_j > 0$ und $m \geq 1$ mit $p_{ji}^{(m)} > 0$.
- Aus $\pi = \pi P^m$ folgt:

$$\pi_i = \sum_{k \in S} \pi_k \cdot p_{ki}^{(m)} \geq \pi_j \cdot p_{ji}^{(m)} > 0$$

- Da mindestens ein $\pi_j > 0$ existiert (π ist W-Vektor), folgt $\pi_i > 0$ für alle i .

Die invariante Verteilung ist eindeutig

Angenommen, π und $\tilde{\pi}$ sind zwei invariante Verteilungen.

Definiere $f := \pi - \tilde{\pi}$. Dann gilt:

- $f \cdot P = f$ (Differenz zweier Fixpunkte ist Fixpunkt)
- $\sum_j f_j = 1 - 1 = 0$

Sei $i^* = \arg \max_i f_i$. Aus $f = fP$ folgt:

$$f_{i^*} = \sum_j p_{i^*j} f_j \leq f_{i^*} \cdot \underbrace{\sum_j p_{i^*j}}_{=1} = f_{i^*}$$

Gleichheit nur wenn $f_j = f_{i^*}$ für alle j mit $p_{i^*j} > 0$.

Schluss per Irreduzibilität

Wir haben: $f_j = f_{i^*}$ für alle j mit $p_{i^*j} > 0$.

- Wenn $f_j = f_{i^*}$ und $p_{jk} > 0$, dann auch $f_k = f_{i^*}$.
- Da die Kette **irreduzibel** ist, erreicht man von i^* jeden Zustand.
- Also: $f_k = f_{i^*}$ für **alle** $k \in S$.
- Da $\sum_k f_k = 0$ und alle f_k gleich: $|S| \cdot f_{i^*} = 0 \Rightarrow f_{i^*} = 0$.
- Damit $f = 0$, d.h. $\pi = \tilde{\pi}$. □

Bei Aperiodizität: $P^n \rightarrow \Pi$ (alle Zeilen = π)

- **Variationsabstand:** $\|u - v\|_{TV} = \frac{1}{2} \sum_i |u_i - v_i|$.
- Für die Verteilung $e_i P^n$ (Start in i):

$$\|e_i P^n - \pi\|_{TV} \leq \|e_i - \pi\|_{TV} \cdot \rho^n$$

wobei $\rho < 1$ (Kontraktion bei Irreduzibilität + Aperiodizität).

- Da $\rho^n \rightarrow 0$: Konvergenz gegen π für jeden Startzustand. $\square$

Markov-Ketten

Warum gibt es ein $\rho < 1$?

Schlüsselidee

Endlich + irreduzibel + aperiodisch $\Rightarrow$ es gibt ein $m \geq 1$ mit $P^m > 0$.

Also hat nach m Schritten jede Zeile von P^m überall etwas Masse.

Folge

Dann gibt es ein $c > 0$ mit

$$\|\mu P^m - \nu P^m\|_{TV} \leq (1 - c) \|\mu - \nu\|_{TV}$$

für alle Verteilungen μ, ν . Durch Wiederholung folgt

$$\|\mu P^n - \pi\|_{TV} \leq C \rho^n \quad (0 < \rho < 1)$$

also geometrische Konvergenz.

Wetter-Beispiel: Potenzen von P

$$P^5 \approx \begin{pmatrix} 0.672 & 0.328 \\ 0.656 & 0.344 \end{pmatrix}, \quad P^{20} \approx \begin{pmatrix} 0.667 & 0.333 \\ 0.667 & 0.333 \end{pmatrix}$$

- Die Zeilen von P^n konvergieren beide gegen $\pi = (2/3, 1/3)$.
- Egal ob Start in Sonne oder Regen – langfristig gleiche Verteilung!

Verifikation

$$\pi P = \left(\frac{2}{3} \cdot 0.8 + \frac{1}{3} \cdot 0.4, \frac{2}{3} \cdot 0.2 + \frac{1}{3} \cdot 0.6 \right) = \left(\frac{2}{3}, \frac{1}{3} \right) \checkmark$$

Markov-Ketten

Beispiel: Invariante Verteilung (3 Zustände)

Stimmungs-Modell

$$P = \begin{pmatrix} 0.5 & 0.4 & 0.1 \\ 0.3 & 0.4 & 0.3 \\ 0.2 & 0.3 & 0.5 \end{pmatrix}$$

Gesucht: $\pi = (\pi_G, \pi_N, \pi_S)$ mit $\pi P = \pi$, $\sum \pi_i = 1$.

Gleichungssystem:

$$0.5\pi_G + 0.3\pi_N + 0.2\pi_S = \pi_G$$

$$0.4\pi_G + 0.4\pi_N + 0.3\pi_S = \pi_N$$

$$\pi_G + \pi_N + \pi_S = 1$$

Lösung: $\pi = (\frac{1}{3}, \frac{11}{30}, \frac{3}{10}) \approx (0.333, 0.367, 0.300)$

Definition (Detailed Balance)

π erfüllt die **Detailed-Balance-Bedingung** bzgl. P , falls:

$$\pi_i \cdot p_{ij} = \pi_j \cdot p_{ji} \quad \text{für alle } i, j \in S$$

Satz: Detailed Balance $\Rightarrow \pi$ invariant

$$(\pi P)_j = \sum_i \pi_i p_{ij} \stackrel{\text{DB}}{=} \sum_i \pi_j p_{ji} = \pi_j \underbrace{\sum_i p_{ji}}_{=1} = \pi_j \quad \square$$

Intuition: Flussgleichgewicht

$\pi_i p_{ij}$ = “Fluss” von i nach j im Gleichgewicht.

DB: Fluss $i \rightarrow j$ = Rückfluss $j \rightarrow i$ für jedes Paar $\Rightarrow$ Gleichgewicht.

Wetter-Beispiel: Prüfe Detailed Balance

$$\pi = (2/3, 1/3), \quad P = \begin{pmatrix} 0.8 & 0.2 \\ 0.4 & 0.6 \end{pmatrix}$$

Prüfe $\pi_S \cdot p_{SR} = \pi_R \cdot p_{RS}$:

$$\frac{2}{3} \cdot 0.2 = \frac{2}{15} \quad \text{und} \quad \frac{1}{3} \cdot 0.4 = \frac{2}{15} \quad \checkmark$$

⇒ Das Wetter-Modell ist **reversibel**.

Nicht jede Kette ist reversibel! Kreislauf $1 \rightarrow 2 \rightarrow 3 \rightarrow 1$:

$$P = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{pmatrix}, \quad \pi = (1/3, 1/3, 1/3)$$

Aber: $\pi_1 p_{12} = 1/3 \neq 0 = \pi_2 p_{21}$ – Detailed Balance verletzt!

Markov-Ketten

Anwendung: Google PageRank

Idee (Brin & Page, 1998)

Das Web ist ein gerichteter Graph. Ein “Random Surfer” klickt zufällig auf Links der aktuellen Seite $\Rightarrow$ Markov-Kette!

Naives Modell

Zustandsraum $S = \{\text{Webseiten}\}$, Übergangsmatrix:

$$p_{ij} = \begin{cases} \frac{1}{\text{out}(i)} & \text{falls } i \rightarrow j \text{ (Link vorhanden)} \\ 0 & \text{sonst} \end{cases}$$

wobei $\text{out}(i)$ die Anzahl ausgehender Links von Seite i ist.

Problem: Nicht irreduzibel (Sackgassen) und evtl. periodisch!

Lösung: Dämpfungsfaktor $\alpha \in (0, 1)$

$$G = \alpha \cdot P + (1 - \alpha) \cdot \frac{1}{|S|} \mathbf{1}\mathbf{1}^T$$


Mit Wahrscheinlichkeit α : folge einem Link.

Mit Wahrscheinlichkeit $1 - \alpha$: springe zu einer zufälligen Seite.

Eigenschaften von G (typisch: $\alpha = 0.85$)

- Alle Einträge $> 0 \Rightarrow$ **irreduzibel** und **aperiodisch**.
- Hauptsatz anwendbar: $\exists!$ invariante Verteilung π .
- $\pi_i =$ **PageRank** der Seite i (Wichtigkeit).

Mini-Web mit 4 Seiten



Naive Matrix (D ist Sackgasse für Random Surfer ohne Dämpfung):

$$P = \begin{pmatrix} 0 & 1/2 & 1/2 & 0 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

Google-Matrix mit $\alpha = 0.85$

$$G = 0.85 \cdot P + 0.15 \cdot \frac{1}{4} \mathbf{1} \mathbf{1}^T$$

Berechnung von π

Iteriere: $\mu_{n+1} = \mu_n \cdot G$ (Power-Iteration), bis Konvergenz.

Ergebnis (gerundet)

$$\pi \approx (0.37, 0.20, 0.29, 0.14)$$

Ranking: $A > C > B > D$

Seite A hat den höchsten PageRank, weil C (selbst wichtig) auf A verlinkt.

Modell

Ein Kartendeck mit n Karten = eine Permutation $\sigma \in S_n$.

Zustandsraum: $S = S_n$ (alle $n!$ Permutationen).

Ein Mischvorgang $\hat{=}$ ein Übergang $\sigma \rightarrow \sigma'$.

Beispiel: Top-to-Random Shuffle

Nimm die oberste Karte und stecke sie an eine zufällige Position:

$$p_{\sigma, \sigma'} = \begin{cases} \frac{1}{n} & \text{falls } \sigma' \text{ durch Einfügen der Top-Karte entsteht} \\ 0 & \text{sonst} \end{cases}$$

Markov-Eigenschaft: Die nächste Anordnung hängt nur von der aktuellen ab!

Eigenschaften der Misch-Kette

- **Irreduzibel:** Jede Permutation ist von jeder anderen erreichbar.
- **Aperiodisch:** Top-Karte kann an gleicher Stelle bleiben ($p_{\sigma\sigma} = 1/n > 0$).
- $\Rightarrow$ Hauptsatz anwendbar!

Invariante Verteilung

Die Gleichverteilung $\pi(\sigma) = \frac{1}{n!}$ ist invariant (Symmetrie). Da irreduzibel: sie ist die **eindeutige** invariante Verteilung.

Mischzeit (Mixing Time)

Wie viele Schritte bis “gut gemischt” ($\|\mu_n - \pi\|_{TV} < \varepsilon$)?
Top-to-Random: $\approx n \ln n$ Schritte (für $n = 52$: ca. 200).

Zentrale Begriffe

- **Markov-Kette:** Zukunft hängt nur von Gegenwart ab.
- **Stochastische Matrix:** Zeilensummen = 1, Einträge ≥ 0 .
- **Invariante Verteilung:** $\pi P = \pi$ (Gleichgewicht).
- **Irreduzibel:** Jeder Zustand von jedem erreichbar.
- **Aperiodisch:** Keine periodischen Zyklen.

Hauptsatz

Irreduzibel + endlich $\Rightarrow$ genau eine invariante Verteilung $\pi > 0$.
+ Aperiodisch $\Rightarrow$ Konvergenz: $P^n \rightarrow$ Matrix mit Zeilen π .

Markov Chain Monte Carlo

Zufallszahlen, Simulation und Integration

Problem

Computer sind deterministisch – wie erzeugt man “Zufall”?

Pseudozufallszahlen

- Lineare Kongruenzgeneratoren: $x_{n+1} = (ax_n + c) \bmod m$
- Erzeugen gleichverteilte Zahlen in $\{0, 1, \dots, m-1\}$.
- Periodisch, aber Periode kann sehr groß sein.

Andere Verteilungen?

Gleichverteilung ist einfach – aber wie sampelt man aus komplizierten Verteilungen π (z.B. Normalverteilung, Boltzmann, Posterior)?

Grundidee

Konstruiere eine Markov-Kette, deren **invariante Verteilung** genau die gewünschte Zielverteilung π ist.

Vorgehen

- 1 Wähle Startzustand X_0 beliebig.
- 2 Simuliere die Kette: $X_0, X_1, X_2, \dots$
- 3 Nach genügend Schritten (Burn-in): $X_n \sim \pi$ (approximativ).
- 4 Verwende $X_n, X_{n+1}, \dots$ als Stichprobe aus π .

Warum funktioniert das?

Hauptsatz: Irreduzibel + aperiodisch $\Rightarrow X_n \rightarrow \pi$ in Verteilung!

Gegeben

- Zielverteilung π (bis auf Normierung bekannt): $\pi(x) \propto f(x)$
- Vorschlagsverteilung $q(y | x)$ (frei wählbar, leicht zu sampeln)

Algorithmus (ein Schritt: $X_n = x \rightarrow X_{n+1} = ?$)

- 1 Ziehe Vorschlag $y \sim q(\cdot | x)$.
- 2 Berechne Akzeptanzwahrscheinlichkeit (eine **Zahl** $\in [0, 1]$):

$$\alpha(x, y) = \min\left(1, \frac{\pi(y) q(x | y)}{\pi(x) q(y | x)}\right)$$

- 3 Ziehe $U \sim \text{Uniform}(0, 1)$.
- 4 Falls $U < \alpha(x, y)$: setze $X_{n+1} = y$ (**akzeptiere**).
Sonst: setze $X_{n+1} = x$ (**ablehne**, bleibe stehen).

Was ist $P(x, y)$?

$P(x, y)$ = Wahrscheinlichkeit, von x nach y zu springen (für $x \neq y$).

Der **einzige Weg** von x nach y : Vorschlag y UND Akzeptanz.

Definition der Übergangsmatrix

$$P(x, y) = \underbrace{q(y \mid x)}_{\text{W'keit, dass } y \text{ vorgeschlagen wird}} \cdot \underbrace{\alpha(x, y)}_{\text{W'keit, dass akzeptiert wird}} \quad (x \neq y)$$

Dies ist der Multiplikationssatz: $P(A \cap B) = P(A) \cdot P(B \mid A)$.

Verbleibe-Wahrscheinlichkeit

$$P(x, x) = 1 - \sum_{y \neq x} P(x, y) \quad (\text{alles was übrig bleibt})$$

Satz: π erfüllt Detailed Balance bzgl. P

$$\pi(x) P(x, y) = \pi(y) P(y, x) \quad \text{für alle } x \neq y$$

Warum?

α ist genau so konstruiert, dass die “Flüsse” balanciert sind:

$\alpha(x, y) = \min\left(1, \frac{\pi(y)q(x|y)}{\pi(x)q(y|x)}\right)$ korrigiert die Asymmetrie von q und π .

Beweis

O.B.d.A. $\pi(x)q(y|x) \geq \pi(y)q(x|y)$. Dann:

$$\alpha(x, y) = \frac{\pi(y)q(x|y)}{\pi(x)q(y|x)} \leq 1 \quad \text{und} \quad \alpha(y, x) = 1.$$

Linke Seite:

$$\pi(x) P(x, y) = \pi(x) q(y|x) \cdot \frac{\pi(y) q(x|y)}{\pi(x) q(y|x)} = \pi(y) q(x|y)$$

Rechte Seite:

$$\pi(y) P(y, x) = \pi(y) q(x|y) \cdot \underbrace{\alpha(y, x)}_{=1} = \pi(y) q(x|y)$$

Ergebnis

$$\pi(x)P(x, y) = \pi(y)q(x|y) = \pi(y)P(y, x) \quad \checkmark \quad \Rightarrow \pi \text{ ist invariant!}$$



Warum konvergiert MH zur Zielverteilung π ?

Drei Voraussetzungen des Hauptsatzes sind erfüllt:

- ① π ist **invariant**: Detailed Balance (gerade bewiesen).
- ② **Irreduzibel**: Falls $q(y | x) > 0$ für alle x, y , dann:

$$P(x, y) = q(y|x) \cdot \alpha(x, y) > 0 \quad \forall x \neq y$$

Jeder Zustand ist in einem Schritt erreichbar.

- ③ **Aperiodisch**: Vorschlag kann abgelehnt werden $\Rightarrow$
 $P(x, x) > 0$ (Selbstschleife) $\Rightarrow d(x) = 1$.

Schlussfolgerung (Hauptsatz)

Irreduzibel + aperiodisch $\Rightarrow P^n \rightarrow \pi$ (Konvergenz!)

Die Normierungskonstante von π wird **nie** benötigt (α enthält nur Verhältnisse).

Symmetrischer Vorschlag: $q(y | x) = q(x | y)$

Dann vereinfacht sich die Akzeptanzwahrscheinlichkeit zu:

$$\alpha(x, y) = \min\left(1, \frac{\pi(y)}{\pi(x)}\right)$$

Interpretation

- $\pi(y) \geq \pi(x)$: Vorschlag wird **immer** akzeptiert (bergauf).
- $\pi(y) < \pi(x)$: Vorschlag wird mit W'keit $\pi(y)/\pi(x)$ akzeptiert (bergab).

⇒ Die Kette besucht häufiger Zustände mit hohem π -Wert!

Typischer Vorschlag

$q(y | x) = \mathcal{N}(x, \sigma^2)$ (Random Walk Metropolis)

Trick: künstliche Verteilung einführen

Für

$$I = \int h(x) dx$$

wähle π mit $\pi(x) > 0$ auf dem relevanten Bereich. Dann:

$$I = \int \frac{h(x)}{\pi(x)} \pi(x) dx = \mathbb{E}_{\pi} \left[\frac{h(X)}{\pi(X)} \right]$$

Ergodentheorem

$$\frac{1}{N} \sum_{n=1}^N f(X_n) \xrightarrow{N \rightarrow \infty} \mathbb{E}_{\pi}[f] \quad (\text{fast sicher})$$

Hier: $f(x) = h(x)/\pi(x)$.

Schätzer für ein allgemeines Integral

Nach Burn-in B :

$$\hat{I}_N = \frac{1}{N - B} \sum_{n=B+1}^N \frac{h(X_n)}{\pi(X_n)}$$

als Näherung für $I = \int h(x) dx$.

Spezialfall

Will man schon $\mathbb{E}_\pi[g] = \int g(x) \pi(x) dx$ berechnen, genügt einfach

$$\frac{1}{N - B} \sum_{n=B+1}^N g(X_n)$$

ohne den Faktor $1/\pi(X_n)$.

Ziel

Sample aus $\pi(x) \propto e^{-x^2/2}$ (Standardnormalverteilung).

Random Walk Metropolis

- 1 Start: $X_0 = 0$.
- 2 Vorschlag: $y = X_n + \varepsilon$, $\varepsilon \sim \text{Uniform}(-\delta, \delta)$.
- 3 Akzeptanz: $\alpha = \min\left(1, \frac{e^{-y^2/2}}{e^{-X_n^2/2}}\right) = \min\left(1, e^{(X_n^2 - y^2)/2}\right)$.
- 4 $U \sim \text{Uniform}(0, 1)$: Falls $U < \alpha$, setze $X_{n+1} = y$, sonst $X_{n+1} = X_n$.

Nach Burn-in: Histogramm von $(X_n) \approx$ Glockenkurve!

Wo wird MCMC eingesetzt?

- **Bayessche Statistik:** Sampling aus Posterior-Verteilungen.
- **Statistische Physik:** Simulation von Ising-Modellen, Boltzmann-Verteilungen.
- **Machine Learning:** Training von Boltzmann-Maschinen, Variational Inference.
- **Kombinatorische Optimierung:** Simulated Annealing.
- **Numerische Integration:** Hochdimensionale Integrale.

Zusammenhang zu Markov-Ketten

MCMC **konstruiert** eine Markov-Kette mit gewünschtem π .
Hauptsatz garantiert Konvergenz. Detailed Balance liefert Korrektheit.